
Universidad Panamericana

Ciudad UP

Series de Tiempo

Modelación y pronóstico con SARIMA, SARIMAX y GARCH

Johnson & Johnson
Ganancias trimestrales
1960–1980

Temperatura en Dublín
Temperatura mensual
2014–2016

ETF SPY
Precios diarios
2014–2019

Autoras:

Daniela Cojab
Sofía Palma

Finanzas Cuantitativas
Dr. César Galindo
Examen Final

Abstract

Este trabajo analiza tres series temporales con propiedades distintas mediante metodologías ARIMA/SARIMA, extensiones SARIMAX y modelos GARCH para la volatilidad. Para **Johnson & Johnson** (ganancias trimestrales 1960–1980) se seleccionó SARIMA(0, 1, 1)(1, 1, 0)₄, que captura la tendencia de crecimiento sostenido y la estacionalidad trimestral. Para la **temperatura en Dublín** (2014–2016) se ajustó SARIMA(1, 0, 0)(2, 1, 0)₁₂, consistente con la estacionalidad anual dominante. Para el **ETF SPY** (2014–2019), la modelación en dos etapas combina ARIMA(3, 1, 4) para la media condicional con GARCH(1, 1) para la varianza condicional, revelando *clustering* de volatilidad significativo. Los modelos EGARCH y GJR-GARCH exploran asimetría en el impacto de los choques.

Palabras clave: SARIMA, SARIMAX, GARCH, EGARCH, GJR-GARCH, series de tiempo financieras, pronóstico, volatilidad condicional, Box-Jenkins.

Contents

1	Introducción	4
2	Metodología general	4
2.1	Modelos SARIMA	4
2.2	Extensión SARIMAX	5
2.3	Modelos GARCH para la varianza condicional	5
3	Resumen comparativo global	5
4	Análisis de Johnson & Johnson	5
4.1	Serie original y transformaciones	5
4.2	ACF y PACF	6
4.3	Modelo SARIMA seleccionado	6
4.4	Diagnóstico de residuales	6
4.5	Extensión SARIMAX para Johnson & Johnson	6
5	Análisis de la temperatura en Dublín	7
5.1	Serie mensual y descomposición	7
5.2	Modelo SARIMA seleccionado	7
5.3	Extensión SARIMAX para Dublín	7
6	Predicción del ETF SPY	7
6.1	Serie de precios y rendimientos	8
6.2	ACF y PACF de rendimientos	8
6.3	Modelo ARIMA para la media condicional	8
6.4	Modelación GARCH de la varianza condicional	8
7	Conclusiones	9
Parte II — Ejercicios Propuestos con Procedimientos		10
Parte A — Ejercicios analíticos		10
Ejercicio 1 — Identificación SARIMAX		10
Ejercicio 2 — Prueba ARCH y motivación GARCH		11
Ejercicio 3 — Estimación GARCH(1,1)		12
Ejercicio 4 — GJR-GARCH y efecto apalancamiento		14
Ejercicio 5 — EGARCH: logaritmo de varianza		15
Ejercicio 6 — GARCH-M		16
Ejercicio 7 — Validación ARIMA-GARCH		17
Ejercicio 8 — VaR dinámico con GARCH		18
Ejercicio 9 — SARIMAX multivariable		19
Ejercicio 10 — Selección de modelo		20
Parte B — Preguntas estilo CFA		22
Pregunta CFA 11		22
Pregunta CFA 12		22
Pregunta CFA 13		22
Pregunta CFA 14		23

Pregunta CFA 15	23
Pregunta CFA 16	24
Pregunta CFA 17	24
Pregunta CFA 18	24
Pregunta CFA 19	25
Pregunta CFA 20	25
Referencias	27

1 Introducción

Las series de tiempo son observaciones ordenadas cronológicamente que aparecen en economía, finanzas, climatología y ciencias de datos. Su análisis permite detectar patrones sistemáticos, cuantificar dependencia temporal y construir modelos con capacidad predictiva.

Este proyecto estudia tres ejemplos canónicos con características contrastantes:

- **Johnson & Johnson:** ganancias trimestrales por acción (1960–1980), con tendencia exponencial y estacionalidad trimestral. Véase [Sección 4](#).
- **Temperatura en Dublín:** temperatura media mensual (2014–2016), con fuerte estacionalidad anual y tendencia débil. Véase [Sección 5](#).
- **ETF SPY:** precios de cierre diarios del fondo S&P 500 ETF Trust (2014–2019), no estacionario en niveles y con volatilidad heterocedástica. Véase [Sección 6](#).

2 Metodología general

Se siguió el protocolo de [Box-Jenkins](#) extendido con diagnóstico de heterocedasticidad:

1. Visualización de la serie original y detección de tendencia, estacionalidad y cambios de varianza.
2. Transformaciones estabilizadoras (logarítmica, diferenciación).
3. Pruebas de estacionariedad: Dickey-Fuller Aumentada (ADF).
4. Estudio de ACF y PACF para identificación de órdenes.
5. Ajuste y selección de modelos ARIMA/SARIMA por criterio AIC.
6. Extensión a SARIMAX con variables exógenas cuando fue pertinente.
7. Modelación de la varianza condicional: GARCH, EGARCH y GJR-GARCH.
8. Validación mediante diagnóstico completo de residuales.
9. Construcción de pronósticos con intervalos de confianza al 95%.

2.1 Modelos SARIMA

La familia SARIMA generaliza el proceso ARIMA al incorporar componentes estacionales [2]:

$$\Phi_P(B^s) \phi_p(B) (1 - B)^d (1 - B^s)^D y_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (1)$$

donde B es el operador de rezago, s el periodo estacional, (p, d, q) los órdenes regulares y (P, D, Q) los órdenes estacionales.

2.2 Extensión SARIMAX

El modelo SARIMAX añade un vector de variables exógenas $\mathbf{x}_t$ [6]:

$$\Phi_P(B^s) \phi_p(B) (1 - B)^d (1 - B^s)^D y_t = \beta^\top \mathbf{x}_t + \Theta_Q(B^s) \theta_q(B) \varepsilon_t \quad (2)$$

Esto permite incorporar covariables como índices macroeconómicos, variables de calendario o indicadores exógenos relevantes.

2.3 Modelos GARCH para la varianza condicional

Para series financieras con heterocedasticidad condicional, la varianza σ_t^2 no es constante. El GARCH(p, q) [1] especifica:

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0, 1) \quad (3)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \quad (4)$$

con $\omega > 0$, $\alpha_i \geq 0$, $\beta_j \geq 0$ y $\sum_i \alpha_i + \sum_j \beta_j < 1$.

El EGARCH(1, 1) [8] trabaja con $\log \sigma_t^2$, capturando asimetría:

$$\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \alpha \left(\frac{|\varepsilon_{t-1}|}{\sigma_{t-1}} - \sqrt{\frac{2}{\pi}} \right) + \gamma \frac{\varepsilon_{t-1}}{\sigma_{t-1}} \quad (5)$$

El GJR-GARCH(1, 1, 1) [5] añade un término de apalancamiento:

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \lambda \varepsilon_{t-1}^2 \mathbf{1}_{\{\varepsilon_{t-1} < 0\}} + \beta \sigma_{t-1}^2 \quad (6)$$

3 Resumen comparativo global

Table 1: Resumen ejecutivo de las tres series analizadas

Serie	Patrón dominante	Transformación	Modelo final	Di
J&J	Tendencia + estacional trim.	$\log + \Delta$	SARIMA(0, 1, 1)(1, 1, 0) ₄	Re
Dublín	Estacional anual fuerte	Δ_{12}	SARIMA(1, 0, 0)(2, 1, 0) ₁₂	LE
ETF SPY	No estacionario + ARCH	$\Delta \log$	ARIMA(3, 1, 4) + GARCH(1, 1)	Ch

4 Análisis de Johnson & Johnson

4.1 Serie original y transformaciones

La serie de ganancias trimestrales de J&J exhibe crecimiento exponencial sostenido (la varianza crece con el nivel) y estacionalidad trimestral regular. La transformación

logarítmica estabiliza la varianza y linealiza la tendencia; la primera diferencia elimina la no estacionariedad en media.

4.2 ACF y PACF

Las funciones ACF y PACF de la serie $\Delta \log(\text{ganancias})$ indican: corte significativo en rezago 1 del ACF (sugiere MA(1)), caída exponencial del PACF (confirma MA(1) regular) y autocorrelación significativa en rezago 4 (estructura estacional AR(1) con $s = 4$).

4.3 Modelo SARIMA seleccionado

SARIMA(0, 1, 1)(1, 1, 0)₄ en la escala logarítmica

$$(1 - \hat{\Phi}B^4)(1 - B)(1 - B^4) \log y_t = (1 + \hat{\theta}B) \varepsilon_t$$

$$\text{AIC} = -150.91 \quad \hat{\theta} = -0.6799 [\text{MA}(1)] \quad \hat{\Phi} = -0.3217 [\text{SAR}(1)]$$

Table 2: Modelos SARIMA candidatos para Johnson & Johnson

Orden regular	Orden estacional	AIC	SSE	p-val LB
(0, 1, 1)	(1, 1, 0) ₄	-150.91	0.625	0.708
(0, 1, 1)	(0, 1, 1) ₄	-150.75	0.627	0.609
(0, 1, 1)	(1, 1, 1) ₄	-149.13	0.623	0.678
(1, 1, 1)	(1, 1, 0) ₄	-148.92	0.625	0.720
(1, 1, 1)	(0, 1, 1) ₄	-148.77	0.626	0.595

4.4 Diagnóstico de residuales

El modelo SARIMA(0, 1, 1)(1, 1, 0)₄ captura correctamente la dinámica de las ganancias de J&J. Los residuales son compatibles con ruido blanco (Ljung-Box $p = 0.708$) y presentan distribución aproximadamente normal, validando la inferencia basada en máxima verosimilitud.

4.5 Extensión SARIMAX para Johnson & Johnson

La extensión natural es incluir variables macroeconómicas como el índice de producción industrial (IPI) o variables de calendario:

$$(1 - \hat{\Phi}B^4)(1 - B)(1 - B^4) \log y_t = \beta_1 x_{1t} + \beta_2 x_{2t} + (1 + \hat{\theta}B) \varepsilon_t \quad (7)$$

donde x_{1t} representa el crecimiento del PIB trimestral y x_{2t} una variable indicadora de trimestre fiscal.

5 Análisis de la temperatura en Dublín

5.1 Serie mensual y descomposición

La temperatura media mensual del Aeropuerto de Dublín exhibe estacionalidad anual dominante ($s = 12$) con amplitud de aproximadamente 11°C entre invierno y verano. La tendencia es débil pero ligeramente positiva ($\sim 0.2^\circ\text{C}$ en el periodo), consistente con registros de cambio climático en la región.

5.2 Modelo SARIMA seleccionado

SARIMA(1, 0, 0)(2, 1, 0) ₁₂			
$(1 - \phi_1 B)(1 - \Phi_1 B^{12} - \Phi_2 B^{24})(1 - B^{12}) T_t = \varepsilon_t$			
Parámetro	Coef.	Err. est.	IC 95%
ϕ_1 (AR1)	0.0671	0.264	$[-0.451, 0.585]$
Φ_1 (SAR1)	-0.0593	—	—
Φ_2 (SAR2)	0.9047	—	—

Table 3: Prueba de Ljung-Box sobre los residuales del modelo de Dublín

Rezago	Estadístico	p-valor
4	6.396	0.172
8	7.663	0.467
12	15.905	0.196

5.3 Extensión SARIMAX para Dublín

La **Oscilación del Atlántico Norte (NAO)** influye fuertemente en las temperaturas invernales de Irlanda. El modelo SARIMAX resultante sería:

$$(1 - \phi B)(1 - \Phi_1 B^{12} - \Phi_2 B^{24})(1 - B^{12}) T_t = \beta_{\text{NAO}} \text{NAO}_t + \varepsilon_t \quad (8)$$

El modelo SARIMA(1, 0, 0)(2, 1, 0)₁₂ es adecuado para la temperatura en Dublín. Todos los rezagos en Ljung-Box muestran $p > 0.15$, indicando ausencia de autocorrelación residual. La extensión SARIMAX con índice NAO ofrecería mejoras interpretativas adicionales en meses invernales.

6 Predicción del ETF SPY

6.1 Serie de precios y rendimientos

El ETF SPY registra los precios de cierre diarios del fondo indexado al **S&P 500**. La serie de precios es claramente no estacionaria (ADF no rechaza H_0 de raíz unitaria). Los **log-rendimientos** $r_t = \log(P_t/P_{t-1}) \times 100$ son estacionarios pero exhiben heterocedasticidad condicional (*volatility clustering*), motivando el uso de modelos GARCH.

6.2 ACF y PACF de rendimientos

La ausencia de autocorrelación en r_t pero su presencia en r_t^2 es la *firma característica* del efecto ARCH, justificando la modelación de la varianza condicional.

6.3 Modelo ARIMA para la media condicional

Table 4: Comparativa de especificaciones ARIMA para SPY

Modelo	AIC	BIC	MAE (%)	Mejor
ARIMA(3, 1, 4)	5 990.86	6 038.24	1.9553	✓
ARIMA(1, 2, 4)	6 035.94	6 070.82	1.9637	
ARIMA(5, 1, 4)	6 010.10	6 073.58	1.9519	
ARIMA(1, 1, 1)	6 150.42	6 167.86	1.9695	

6.4 Modelación GARCH de la varianza condicional

Table 5: Comparativa de modelos GARCH para los rendimientos del SPY

Modelo	AIC	BIC	Log-Lik	Mejor
GARCH(1, 1) Normal	4 826.79	4 848.20	-2 409.40	✓
EGARCH(1, 1) t	4 829.77	4 856.54	-2 409.89	
GJR-GARCH(1, 1, 1) t	4 830.67	4 862.79	-2 409.34	

Varianza condicional:

$$\sigma_t^2 = \underbrace{0.036327}_{\omega} + \underbrace{0.0738}_{\alpha} \varepsilon_{t-1}^2 + \underbrace{0.9011}_{\beta} \sigma_{t-1}^2$$

Persistencia: $\alpha + \beta = 0.9749$ (alta, típica en renta variable)

Interpretación: $\hat{\omega}$ fija el nivel de largo plazo $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta) \approx 1.44\%^2$. $\hat{\alpha} = 0.0738$ mide el efecto inmediato de un choque. $\hat{\beta} = 0.9011$ mide la persistencia: los choques tardan muchos periodos en disiparse, explicando el *clustering* observado.

La modelación en dos etapas ARIMA(3, 1, 4)+GARCH(1, 1) proporciona el mejor ajuste global para el SPY. La persistencia GARCH alta ($\alpha + \beta = 0.975$) confirma el largo *memory* de la volatilidad financiera. Los modelos EGARCH y GJR-

GARCH no mejoran significativamente el AIC, sugiriendo que la asimetría del efecto apalancamiento es secundaria para este ETF.

7 Conclusiones

1. **Heterogeneidad de series.** No existe un modelo universal: cada serie exige estrategia propia según sus características de tendencia, estacionalidad y heterocedasticidad.
2. **Transformaciones como primer paso.** La inspección gráfica permite detectar tendencia, estacionalidad y heterocedasticidad antes de los modelos formales.
3. **SARIMA para estacionalidad determinista.** SARIMA(0, 1, 1)(1, 1, 0)₄ para J&J y SARIMA(1, 0, 0)(2, 1, 0)₁₂ para Dublín capturan sus patrones con residuales ruido blanco.
4. **GARCH es indispensable en finanzas.** El *clustering* de volatilidad del SPY hace inadecuado cualquier modelo de varianza constante. GARCH(1, 1) lo captura de manera parsimoniosa.
5. **SARIMAX amplía la capacidad explicativa.** NAO para Dublín, VIX para SPY, PIB para J&J mejoran ajuste y pronóstico, siempre que las covariables sean genuinamente exógenas.
6. **Validación residual es condición necesaria.** AIC bajo es necesario pero no suficiente. Ljung-Box, diagnóstico gráfico y ausencia de autocorrelación en $\hat{z}_t^2$ son pasos ineludibles.

Parte II — Ejercicios Propuestos con Procedimientos

Instrucciones generales

Los siguientes ejercicios corresponden a **Licenciatura en Finanzas Cuantitativas**. La **Parte A** contiene ejercicios analíticos con procedimiento completo. La **Parte B** sigue el formato de opción múltiple **CFA Level III**, con justificación de cada respuesta.

Parte A — Ejercicios analíticos

Ejercicio 1 — Identificación SARIMAX con variable exógena

Sea y_t el logaritmo del precio mensual de un bono soberano de mercados emergentes (enero 2010 – diciembre 2022, $n = 156$ obs.). Variable exógena: rendimiento del Tesoro de EE.UU. a 10 años, x_t .

Periodo	y_t	x_t (%)	Δy_t
Ene 2022	98.321	1.780	+0.0031
Feb 2022	96.154	1.930	−0.0224
Mar 2022	93.887	2.340	−0.0237
Abr 2022	90.441	2.890	−0.0369
May 2022	88.219	2.970	−0.0246

- Ecuación del modelo SARIMAX(1, 1, 1)(1, 1, 0)₁₂ con variable exógena x_t .
- El ADF sobre y_t arroja estadístico = −1.42, valor crítico 5% = −2.89. ¿Qué?
- $\hat{\beta} = -0.87$ (e.e. = 0.12): interpretación económica y supuesto de exogeneidad.
- Construir el estadístico t e IC al 95% para $\hat{\beta}$.

Solución

a) Ecuación completa del SARIMAX(1, 1, 1)(1, 1, 0)₁₂:

$$\underbrace{(1 - \Phi_1 B^{12})}_{\text{SAR}(1)} \underbrace{(1 - \phi_1 B)}_{\text{AR}(1)} \underbrace{(1 - B)}_{\Delta} \underbrace{(1 - B^{12})}_{\Delta_{12}} y_t = \beta x_t + \underbrace{(1 + \theta_1 B)}_{\text{MA}(1)} \varepsilon_t$$

Identificación de operadores:

- $(1 - \phi_1 B)$: polinomio AR regular de orden $p = 1$.
- $(1 - B)$: diferencia regular de orden $d = 1$.
- $(1 - \Phi_1 B^{12})$: polinomio SAR estacional de orden $P = 1$, periodo $s = 12$.
- $(1 - B^{12})$: diferencia estacional de orden $D = 1$.
- $(1 + \theta_1 B)$: polinomio MA regular de orden $q = 1$.
- βx_t : componente exógeno que entra en la media condicional.
- $p=1, d=1, q=1, P=1, D=1, Q=0, s=12$.

b) Implicación del ADF para la diferenciación:

El estadístico $ADF = -1.42 > -2.89$ (valor crítico al 5%), por lo tanto **no se rechaza** H_0 de raíz unitaria. Esto indica que y_t es no estacionaria en media, lo que **es congruente con** $d = 1$ en el modelo. Una primera diferencia es necesaria y suficiente para inducir estacionariedad.

c) Interpretación de $\hat{\beta} = -0.87$:

Signo negativo: cuando el rendimiento del Tesoro de EE.UU. sube 1 punto porcentual, el logaritmo del precio del bono soberano disminuye en promedio 0.87 unidades, ceteris paribus. Esto es económicamente coherente: tasas libres de riesgo más altas elevan el costo de oportunidad de los bonos de mercados emergentes, reduciendo su precio (relación inversa precio-tasa).

Magnitud: un aumento de 100 bps en x_t implica una caída de $\approx 0.87\%$ en el log-precio (equivalente a $\approx 0.87\%$ en el nivel de precio para cambios pequeños).

Supuesto de exogeneidad estricta: se requiere $\text{Cov}(x_t, \varepsilon_s) = 0$ para todo t, s . Es decir, el rendimiento del Tesoro de EE.UU. no debe ser influenciado por las perturbaciones del bono soberano (esto es razonable: EE.UU. es económicamente dominante frente al mercado emergente individual).

d) Estadístico t e intervalo de confianza al 95%:

$$t = \frac{\hat{\beta}}{\widehat{\text{e.e.}}(\hat{\beta})} = \frac{-0.87}{0.12} = -7.25$$

Bajo $H_0 : \beta = 0$, con $n = 156$ obs. y distribución asintóticamente normal: $z_{0.025} = 1.96$.

$$\text{IC}_{95\%}(\beta) : \hat{\beta} \pm 1.96 \times 0.12 = -0.87 \pm 0.2352 = [-1.1052, -0.6348]$$

Conclusión: Como $|t| = 7.25 > 1.96$, se rechaza H_0 al 5%. El intervalo de confianza no contiene el cero. $\hat{\beta}$ es **altamente significativo**, confirmando que el rendimiento del Tesoro es una variable exógena relevante para el precio del bono soberano.

Ejercicio 2 — Prueba ARCH y motivación del GARCH

Log-rendimientos diarios del VIX: $r_t = \log(\text{VIX}_t/\text{VIX}_{t-1})$, $n = 1\,000$ obs.

Prueba	Estadístico	p-valor
LM-ARCH (5)	47.83	0.000 004
LM-ARCH (10)	62.11	0.000 000

Solución

a) Hipótesis nula de la prueba LM-ARCH:

La prueba de Engle (1982) contrasta:

$$H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_q = 0 \quad (\text{no hay efecto ARCH de orden } q)$$

equivalentemente, $\sigma_t^2 = \omega$ (varianza constante).

La prueba regresa $\hat{\varepsilon}_t^2$ sobre $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-q}^2$:

$$\hat{\varepsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\varepsilon}_{t-1}^2 + \dots + \alpha_q \hat{\varepsilon}_{t-q}^2 + u_t$$

El estadístico $LM = n \cdot R^2 \sim \chi^2(q)$ bajo H_0 .

Conclusión: Para ambos rezagos ($q = 5$ y $q = 10$), los p-valores son prácticamente cero. Se rechaza H_0 contundentemente: existe heterocedasticidad condicional significativa. Un modelo GARCH es apropiado.

b) Si $r_t \sim \text{ARCH}(1)$, entonces r_t^2 sigue un $\text{AR}(1)$ en covarianza:

Por definición $\text{ARCH}(1)$:

$$r_t = \sigma_t z_t, \quad \sigma_t^2 = \omega + \alpha_1 r_{t-1}^2, \quad z_t \sim \text{i.i.d.}(0, 1)$$

Definamos $u_t = r_t^2 - \sigma_t^2$. Entonces:

$$r_t^2 = \sigma_t^2 + u_t = \omega + \alpha_1 r_{t-1}^2 + u_t$$

Para mostrar que u_t es ruido blanco:

$$\mathbb{E}[u_t] = \mathbb{E}[r_t^2 - \sigma_t^2] = \mathbb{E}[\sigma_t^2 z_t^2 - \sigma_t^2] = \mathbb{E}[\sigma_t^2 (\underbrace{\mathbb{E}[z_t^2 | \mathcal{F}_{t-1}]}_{=1} - 1)] = 0$$

$$\mathbb{E}[u_t u_{t-k}] = \mathbb{E}[(r_t^2 - \sigma_t^2)(r_{t-k}^2 - \sigma_{t-k}^2)]$$

Para $k \geq 1$: σ_t^2 es $\mathcal{F}_{t-1}$ -medible, y $z_t \perp \mathcal{F}_{t-1}$, entonces $\mathbb{E}[u_t | \mathcal{F}_{t-1}] = 0$. Por la ley de expectativas iteradas: $\mathbb{E}[u_t u_{t-k}] = 0$. Por tanto $u_t \sim \text{WN}(0, \sigma_u^2)$.

Queda demostrado que $r_t^2 = \omega + \alpha_1 r_{t-1}^2 + u_t$ es un $\text{AR}(1)$.

c) Limitaciones de modelar r_t^2 con $\text{AR}(1)$ en lugar de GARCH:

- i) **No garantiza positividad:** el $\text{AR}(1)$ sobre r_t^2 puede producir predicciones negativas de la varianza condicional (sin restricción $\omega > 0$, $\alpha \geq 0$), lo que es teóricamente inconsistente.
- ii) **Ineficiencia:** el $\text{AR}(1)$ en r_t^2 es OLS sobre una variable que es heterocedástica por naturaleza (la varianza de $u_t = r_t^2 - \sigma_t^2$ depende de σ_t^4). GARCH usa MV, que es asintóticamente eficiente. Además, el $\text{AR}(1)$ no puede extenderse fácilmente a $\text{GARCH}(p, q)$ con términos de varianza rezagados.

d) Por qué la autocorrelación en r_t^2 y no en r_t indica heterocedasticidad:

La ausencia de autocorrelación en r_t descarta correlación serial en la media: el valor esperado de r_t no depende de sus propios rezagos. Sin embargo, la presencia de autocorrelación en $r_t^2 \approx \sigma_t^2 z_t^2$ indica que los cuadrados sí están correlacionados con sus rezagos, lo que refleja que la *magnitud* de los rendimientos (la volatilidad) es predecible a partir de información pasada. Esto es exactamente la heterocedasticidad condicional: $\mathbb{E}[r_t^2 | \mathcal{F}_{t-1}] = \sigma_t^2 \neq \text{cte}$, aunque $\mathbb{E}[r_t | \mathcal{F}_{t-1}] = 0$.

Ejercicio 3 — Estimación e interpretación del GARCH(1,1)

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim N(0, 1), \quad \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2.$$

Parám.	Estimado	Err. est.	p-valor
$\hat{\mu}$	0.0412	0.0318	0.1947
$\hat{\omega}$	0.0285	0.0091	0.0018
$\hat{\alpha}$	0.0830	0.0142	0.0000
$\hat{\beta}$	0.9010	0.0181	0.0000

Solución

a) Verificación de estacionariedad en covarianza:

La condición es $\hat{\alpha} + \hat{\beta} < 1$:

$$\hat{\alpha} + \hat{\beta} = 0.0830 + 0.9010 = 0.984 < 1$$

Sí se cumple. El proceso GARCH(1,1) es estacionario en covarianza. La varianza incondicional existe y es finita.

b) Varianza incondicional anualizada:

$$\bar{\sigma}^2 = \frac{\hat{\omega}}{1 - \hat{\alpha} - \hat{\beta}} = \frac{0.0285}{1 - 0.984} = \frac{0.0285}{0.016} = 1.78125 \%^2$$

Anualizada (252 días de trading):

$$\bar{\sigma}_{\text{anual}}^2 = 1.78125 \times 252 = 448.88 \%^2 \Rightarrow \bar{\sigma}_{\text{anual}} = \sqrt{448.88} \approx 21.19\%$$

c) Cálculo de $\hat{\sigma}_{t+1}^2$ y $\hat{\sigma}_{t+1}$:

Dado $\varepsilon_t = -2.5\%$ y $\hat{\sigma}_t = 1.2\%$:

$$\begin{aligned} \hat{\sigma}_{t+1}^2 &= \hat{\omega} + \hat{\alpha} \varepsilon_t^2 + \hat{\beta} \hat{\sigma}_t^2 = 0.0285 + 0.0830 \times (-2.5)^2 + 0.9010 \times (1.2)^2 \\ &= 0.0285 + 0.0830 \times 6.25 + 0.9010 \times 1.44 \\ &= 0.0285 + 0.5188 + 1.2974 = 1.8447 \%^2 \\ \hat{\sigma}_{t+1} &= \sqrt{1.8447} \approx 1.358\% \end{aligned}$$

El choque negativo grande de -2.5% eleva la volatilidad estimada de 1.2% a 1.36% (incremento de 0.16%).

d) Pronóstico multi-periodo y tasa de reversión:

Se demuestra que el pronóstico de h pasos satisface:

$$\mathbb{E}_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$$

Demostración por recursión: Para $h = 2$:

$$\mathbb{E}_t[\sigma_{t+2}^2] = \omega + \alpha \mathbb{E}_t[\varepsilon_{t+1}^2] + \beta \mathbb{E}_t[\sigma_{t+1}^2] = \omega + (\alpha + \beta)\sigma_{t+1}^2$$

Restando $\bar{\sigma}^2 = \omega/(1 - \alpha - \beta)$ a ambos lados y simplificando se obtiene la fórmula general por inducción.

Interpretación con $\alpha + \beta = 0.984$: Para $h = 10$: $(0.984)^9 = 0.864$, o sea el 86% del desvío persiste a 10 días. Para $h = 50$: $(0.984)^{49} = 0.449$, el 45% persiste. La tasa de reversión es muy lenta: la volatilidad regresa solo 1.6% por periodo hacia su media incondicional $\bar{\sigma}$. Esto implica que los episodios de alta volatilidad tienen efectos prolongados.

Ejercicio 4 — GJR-GARCH y efecto apalancamiento

$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \lambda \varepsilon_{t-1}^2 \mathbf{1}_{\{\varepsilon_{t-1} < 0\}} + \beta \sigma_{t-1}^2$. Para S&P 500: $\hat{\omega} = 0.021$, $\hat{\alpha} = 0.042$, $\hat{\lambda} = 0.078$, $\hat{\beta} = 0.912$.

Solución**a) Interpretación de $\hat{\lambda} = 0.078$ y porcentaje de incremento:**

Una innovación positiva $\varepsilon_{t-1} > 0$ contribuye $\hat{\alpha} \varepsilon_{t-1}^2$ a σ_t^2 . Una innovación negativa de igual magnitud contribuye $(\hat{\alpha} + \hat{\lambda}) \varepsilon_{t-1}^2 = (0.042 + 0.078) \varepsilon_{t-1}^2 = 0.120 \varepsilon_{t-1}^2$. El ratio de impacto:

$$\frac{\hat{\alpha} + \hat{\lambda}}{\hat{\alpha}} = \frac{0.120}{0.042} = 2.857$$

Una **noticia negativa genera 185.7% más volatilidad** que una positiva de igual magnitud ($\hat{\lambda}/\hat{\alpha} = 0.078/0.042 = 1.857$, o sea +185.7%). Una noticia negativa tiene un impacto sobre la varianza condicional 2.857 veces mayor que una noticia positiva de igual magnitud, es decir, 185.7% mayor.

b) Curva de Impacto de Noticias (NIC):

Primero calculamos $\bar{\sigma}^2$. Para GJR-GARCH, la condición de estacionariedad (ver inciso c) da:

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \lambda/2 - \beta} = \frac{0.021}{1 - 0.042 - 0.039 - 0.912} = \frac{0.021}{0.007} = 3.0$$

$$\text{NIC: } \sigma_t^2 = \omega + [\alpha + \lambda \cdot \mathbf{1}_{\varepsilon < 0}] \varepsilon^2 + \beta \bar{\sigma}^2$$

ε	NIC GJR-GARCH	NIC GARCH simétrico	Diferencia
-3	$0.021 + 0.120 \times 9 + 0.912 \times 3 = 3.876$	$0.021 + 0.042 \times 9 + 2.736 = 3.135$	+0.741
-2	$0.021 + 0.120 \times 4 + 2.736 = 3.237$	$0.021 + 0.042 \times 4 + 2.736 = 2.925$	+0.312
-1	$0.021 + 0.120 \times 1 + 2.736 = 2.877$	$0.021 + 0.042 \times 1 + 2.736 = 2.799$	+0.078
0	$0.021 + 0 + 2.736 = 2.757$	2.757	0
+1	$0.021 + 0.042 \times 1 + 2.736 = 2.799$	2.799	0
+2	$0.021 + 0.042 \times 4 + 2.736 = 2.925$	2.925	0
+3	$0.021 + 0.042 \times 9 + 2.736 = 3.135$	3.135	0

La NIC del GJR-GARCH es asimétrica: para $\varepsilon < 0$ está por encima de la NIC simétrica del GARCH; para $\varepsilon > 0$ coinciden.

c) Condición de estacionariedad del GJR-GARCH:

Tomando expectativas: $\mathbb{E}[\sigma_t^2] = \omega + (\alpha + \lambda/2)\mathbb{E}[\varepsilon_{t-1}^2] + \beta\mathbb{E}[\sigma_{t-1}^2]$ (pues $\Pr(\varepsilon < 0) = 1/2$ bajo simetría). La condición es:

$$\hat{\alpha} + \frac{\hat{\lambda}}{2} + \hat{\beta} < 1 \quad \Rightarrow \quad 0.042 + 0.039 + 0.912 = 0.993 < 1 \quad \checkmark$$

Sí se satisface.

d) Relevancia del efecto apalancamiento para el VaR:

El VaR al nivel α es $\text{VaR}_t = \mu - z_\alpha \hat{\sigma}_t$. Si se usa un GARCH simétrico, se subestima $\hat{\sigma}_t$ tras caídas del mercado (noticias negativas grandes), subvalorando el VaR justo cuando el riesgo es mayor. El GJR-GARCH, al asignar mayor peso a choques

negativos, produce estimaciones más precisas del VaR en cola izquierda, especialmente en periodos de crisis. Para portafolios de renta variable, donde el efecto apalancamiento es robusto empíricamente, ignorarlo lleva a capital regulatorio insuficiente.

Ejercicio 5 — EGARCH: logaritmo de la varianza y asimetría

$$\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \alpha(|z_{t-1}| - \sqrt{2/\pi}) + \gamma z_{t-1}.$$

$$\text{ETF High Yield: } \hat{\omega} = -0.085, \hat{\alpha} = 0.112, \hat{\gamma} = -0.063, \hat{\beta} = 0.979.$$

Solución

a) Ventajas del EGARCH frente al GARCH estándar:

i) *Restricciones paramétricas*: el GARCH(1,1) requiere $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$ para garantizar $\sigma_t^2 > 0$. El EGARCH modela $\log \sigma_t^2$, que es automáticamente positivo para cualquier valor de los parámetros (sin restricciones de signo). Esto simplifica la estimación y permite mayor flexibilidad numérica.

ii) *Captura de asimetría*: el GARCH estándar es simétrico: impactos positivos y negativos de igual magnitud tienen el mismo efecto sobre σ_t^2 . El EGARCH incluye el término γz_{t-1} , que captura asimetría: si $\gamma < 0$, los choques negativos ($z_{t-1} < 0$) incrementan más la volatilidad que los positivos (efecto apalancamiento).

b) Interpretación de $\hat{\gamma} = -0.063$:

El término γz_{t-1} añade $\hat{\gamma} z_{t-1}$ a $\log \sigma_t^2$. Cuando $z_{t-1} < 0$ (choque negativo), la contribución $\hat{\gamma} z_{t-1} = -0.063 \times (\text{negativo}) > 0$, **aumentando** $\log \sigma_t^2$.

Sí, **confirma el efecto apalancamiento**: noticias negativas generan mayor volatilidad que positivas de igual magnitud.

Cuantificación: para $z_{t-1} = -1$ vs $z_{t-1} = +1$:

$$\Delta \log \sigma_t^2 = \hat{\gamma}(-1) - \hat{\gamma}(+1) = -2\hat{\gamma} = -2(-0.063) = +0.126$$

Un choque negativo de 1σ eleva $\log \sigma_t^2$ en 0.126 puntos adicionales respecto a un choque positivo de igual magnitud.

c) Impacto marginal de $z_{t-1} = +2$ vs $z_{t-1} = -2$:

El término asimétrico en $\log \sigma_t^2$ es: $f(z) = \hat{\alpha}(|z| - \sqrt{2/\pi}) + \hat{\gamma}z$

Para $z_{t-1} = +2$:

$$f(+2) = 0.112(2 - 0.7979) + (-0.063)(+2) = 0.112 \times 1.2021 - 0.126 = 0.13464 - 0.126 = +0.00864$$

Para $z_{t-1} = -2$:

$$f(-2) = 0.112(2 - 0.7979) + (-0.063)(-2) = 0.112 \times 1.2021 + 0.126 = 0.13464 + 0.126 = +0.26064$$

El choque negativo de -2σ eleva $\log \sigma_t^2$ en 0.261 vs 0.009 del positivo: una diferencia de 0.252 en log-varianza, evidenciando la asimetría.

d) ¿Es $|\hat{\beta}| < 1$ condición suficiente para estacionariedad del EGARCH?

No es suficiente. Para el EGARCH, la condición $|\beta| < 1$ garantiza que el proceso de log-varianza $\log \sigma_t^2$ sea estacionario en media. Sin embargo, para que

σ_t^2 (no su logaritmo) sea estacionario en covarianza (es decir, que $\mathbb{E}[\sigma_t^{2k}] < \infty$ para los momentos relevantes), se requieren condiciones adicionales sobre α y γ . En particular, la existencia de momentos de orden k de σ_t^2 exige: $\mathbb{E}[\exp(k \cdot g(z_t))] < \infty$ donde $g(z)$ es la función de impacto. Para distribuciones de cola pesada, esta condición puede fallar incluso con $|\beta| < 1$.

Ejercicio 6 — GARCH-M: prima de riesgo dependiente de la volatilidad

$$r_t = \mu + \delta\sigma_t + \varepsilon_t, \sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2.$$

Fondo de capital privado (trimestral): $\hat{\mu} = 0.012$, $\hat{\delta} = 0.38$, $\hat{\omega} = 0.0003$, $\hat{\alpha} = 0.11$, $\hat{\beta} = 0.86$.

Solución

a) Interpretación de $\hat{\delta} = 0.38$:

$\hat{\delta} = 0.38 > 0$ indica que existe una **prima de riesgo positiva y significativa**: por cada unidad adicional de volatilidad condicional σ_t (medida en las mismas unidades que r_t), el rendimiento esperado aumenta en 0.38 unidades.

Económicamente: los inversionistas son aversos al riesgo y exigen mayor retorno cuando la volatilidad es más alta. En finanzas de capital privado, donde la liquidez es baja y el riesgo sistémico es relevante, esta relación positiva riesgo-retorno es coherente con la teoría de portafolio (CAPM, APT).

b) Rendimiento esperado si $\hat{\sigma}_t = 0.08$ (8%):

$$\mathbb{E}_t[r_{t+1}] = \hat{\mu} + \hat{\delta}\hat{\sigma}_{t+1} \approx \hat{\mu} + \hat{\delta}\hat{\sigma}_t = 0.012 + 0.38 \times 0.08 = 0.012 + 0.0304 = \mathbf{0.0424}$$

Trimestral: 4.24%. Anualizado (compuesto): $(1.0424)^4 - 1 \approx 18.05\%$.

c) Varianza incondicional de r_t en el GARCH-M:

Tomando varianza incondicional de $r_t = \mu + \delta\sigma_t + \varepsilon_t$:

$$\text{Var}(r_t) = \delta^2 \text{Var}(\sigma_t) + \text{Var}(\varepsilon_t) + 2\delta \text{Cov}(\sigma_t, \varepsilon_t)$$

Dado que $\varepsilon_t = \sigma_t z_t$ con $z_t \perp \mathcal{F}_{t-1}$, y σ_t es $\mathcal{F}_{t-1}$ -medible:

$$\text{Var}(r_t) = \delta^2 \text{Var}(\sigma_t) + \mathbb{E}[\sigma_t^2] = \delta^2 \text{Var}(\sigma_t) + \bar{\sigma}^2$$

donde $\bar{\sigma}^2 = \omega/(1 - \alpha - \beta)$.

Sí difiere del GARCH estándar: en el GARCH-M, $\text{Var}(r_t)$ incluye un término adicional $\delta^2 \text{Var}(\sigma_t) \geq 0$, que refleja la variabilidad en el propio nivel de riesgo a través del tiempo. La varianza incondicional de r_t es mayor que en el GARCH estándar.

Númericamente: $\bar{\sigma}^2 = 0.0003/(1 - 0.11 - 0.86) = 0.0003/0.03 = 0.01$. La varianza adicional $\delta^2 \text{Var}(\sigma_t) > 0$ eleva $\text{Var}(r_t) > 0.01$.

d) Aplicación: Sharpe Ratio dinámico:

El Sharpe Ratio dinámico del portafolio en t sería:

$$\text{SR}_t = \frac{\mathbb{E}_t[r_{t+1}] - r_f}{\hat{\sigma}_{t+1}} = \frac{(\hat{\mu} + \hat{\delta}\hat{\sigma}_{t+1}) - r_f}{\hat{\sigma}_{t+1}} = \frac{\hat{\mu} - r_f}{\hat{\sigma}_{t+1}} + \hat{\delta}$$

Se observa que SR_t converge a $\hat{\delta}$ cuando $\hat{\sigma}_{t+1}$ es grande. Esto permite monitorear si el fondo genera alfa puro ($\hat{\mu} - r_f$) o si el exceso de retorno es puramente compensación por riesgo ($\hat{\delta}\hat{\sigma}_{t+1}$). Se puede estimar en ventanas móviles o en tiempo real con estimaciones GARCH-M recursivas.

Ejercicio 7 — Validación completa de un modelo ARIMA-GARCH

ARIMA(1, 1, 1)+GARCH(1, 1) para rendimientos diarios del MXN/USD.

Prueba	Estad.	p-val	H_0
LB $\hat{z}_t$ (lag 10)	9.841	0.3621	Sin autocorr. en $\hat{z}_t$
LB $\hat{z}_t^2$ (lag 10)	8.203	0.5118	Sin autocorr. en $\hat{z}_t^2$
Jarque-Bera	28.470	0.0000	Normalidad
Sign-Bias Test	1.842	0.0656	Sin asimetría
Negative-Size-Bias	2.971	0.0031	Sin efecto magnitud neg.

Solución

a) ¿Captura el modelo la autocorrelación en media y la heterocedasticidad?

Media (LB $\hat{z}_t$): p-valor = 0.362 > 0.05. No se rechaza H_0 . El modelo ARIMA capturó correctamente la estructura de autocorrelación en la media condicional. Los residuales estandarizados no presentan correlación serial.

Varianza (LB $\hat{z}_t^2$): p-valor = 0.512 > 0.05. No se rechaza H_0 . El GARCH(1, 1) capturó la heterocedasticidad condicional. Los cuadrados de los residuales estandarizados no presentan autocorrelación residual.

Conclusión: la especificación ARIMA-GARCH es adecuada para la media y la varianza. Los problemas identificados son de distribución y asimetría (ver incisos b y c).

b) JB rechaza normalidad (curtosis = 5.2). Distribución alternativa:

Con curtosis > 3 (exceso de curtosis = 5.2 - 3 = 2.2), los datos tienen colas más pesadas que la normal. La distribución **t-Student** con ν grados de libertad es la alternativa natural:

$$z_t \sim t(\nu), \quad \mathbb{E}[z_t] = 0, \quad \text{Var}[z_t] = \frac{\nu}{\nu - 2}, \quad \text{curtosis} = \frac{6}{\nu - 4} + 3 \quad (\nu > 4)$$

Con curtosis = 5.2: $\frac{6}{\nu - 4} = 2.2 \Rightarrow \nu - 4 = 2.73 \Rightarrow \nu \approx 6.7$.

La log-verosimilitud QML bajo $t(\nu)$ estandarizada:

$$\ell(\theta, \nu) = \sum_{t=1}^T \left[\log \Gamma\left(\frac{\nu+1}{2}\right) - \log \Gamma\left(\frac{\nu}{2}\right) - \frac{1}{2} \log[\pi(\nu-2)] - \frac{1}{2} \log \sigma_t^2 - \frac{\nu+1}{2} \log\left(1 + \frac{\hat{z}_t^2}{\nu-2}\right) \right]$$

c) Negative-Size-Bias rechaza H_0 al 1%: implicaciones:

El Negative-Size-Bias Test [4] detecta si choques negativos de *gran magnitud* tienen un efecto desproporcionado sobre la volatilidad futura, no capturado por

el GARCH(1, 1) simétrico. Un rechazo al 1% indica que el modelo subestima la volatilidad tras caídas severas.

Modelo alternativo: **GJR-GARCH**(1, 1, 1) o **EGARCH**(1, 1), ambos capturan asimetría. En particular, el GJR-GARCH con distribución t -Student abordaría simultáneamente los problemas de colas pesadas y asimetría.

d) Protocolo completo de validación GARCH en 5 pasos:

Paso	Objetivo	Prueba	Criterio de éxito
1	Autocorrelación en media	LB sobre $\hat{z}_t$	p-valor > 0.05
2	Heterocedasticidad residual	LB sobre $\hat{z}_t^2$	p-valor > 0.05
3	Distribución de innovaciones	Jarque-Bera o KS	Normalidad o t ajustada
4	Asimetría de choques	Sign-Bias + NSB Test	p-valor > 0.05 en ambos
5	Selección de modelo	AIC / BIC	Menor valor entre candidatos

Ejercicio 8 — VaR dinámico con GARCH

GARCH(1, 1)- t ($\hat{\nu} = 6.2$ g.l.). Posición: \$10 000 000. $\hat{\mu} = 0.045\%$, $\hat{\sigma}_t = 1.84\%$. Cuantiles: $t_{0.05, 6.2} = -1.9432$, $t_{0.01, 6.2} = -3.1427$.

Solución

a) VaR al 95% y 99% a 1 día en dólares:

El VaR en porcentaje:

$$\text{VaR}_{1-p} = -(\hat{\mu} + t_{p, \hat{\nu}} \cdot \hat{\sigma}_t)$$

VaR al 95% ($p = 0.05$):

$$\text{VaR}_{95\%} = -(0.045\% + (-1.9432) \times 1.84\%) = -(0.045\% - 3.5755\%) = 3.531\%$$

En dólares: \$10 000 000 $\times$ 0.03531 = **\$353 100**

VaR al 99% ($p = 0.01$):

$$\text{VaR}_{99\%} = -(0.045\% + (-3.1427) \times 1.84\%) = -(0.045\% - 5.7826\%) = 5.738\%$$

En dólares: \$10 000 000 $\times$ 0.05738 = **\$573 800**

b) Square-root-of-time rule para VaR a 10 días y limitación GARCH:

Regla $\sqrt{h}$:

$$\text{VaR}_{10 \text{ días}} = \text{VaR}_{1 \text{ día}} \times \sqrt{10}$$

$$\text{VaR}_{95\%, 10d} = 3.531\% \times \sqrt{10} = 3.531\% \times 3.162 = 11.16\% \Rightarrow \$1 116 000$$

Limitación en contexto GARCH: la regla $\sqrt{h}$ es exacta solo bajo rendimientos i.i.d. normales con varianza constante. Con GARCH, σ_t^2 es dinámica: si hoy hay alta volatilidad, mañana la volatilidad esperada sigue alta ($\beta \approx 0.90$). El VaR multi-periodo correcto requiere iterar la ecuación GARCH para h pasos:

$$\mathbb{E}_t[\sigma_{t+k}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{k-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$$

y acumular la varianza condicional: $\text{Var}_t(r_{t+1} + \dots + r_{t+h}) = \sum_{k=1}^h \mathbb{E}_t[\sigma_{t+k}^2]$. La regla $\sqrt{h}$ subestima el VaR cuando $\sigma_t > \bar{\sigma}$ (mercados en crisis).

c) Comparación VaR-GARCH vs VaR histórico:

VaR histórico al 99% (varianza constante = 1.84%, distribución normal):

$$\text{VaR}_{99\%,\text{hist}} = -(0.045\% + (-2.326) \times 1.84\%) = 4.235\% \Rightarrow \$423\,500$$

El VaR-GARCH (\$573 800) es 35% mayor. Difieren significativamente cuando: (i) la volatilidad actual $\hat{\sigma}_t$ supera su media histórica $\bar{\sigma}$ (períodos de turbulencia), o (ii) la distribución tiene colas pesadas (aquí la t con $\hat{\nu} = 6.2$ tiene cuantil -3.143 vs -2.326 normal). En mercados tranquilos ($\sigma_t \approx \bar{\sigma}$) ambos convergen.

d) Backtesting de Kupiec (1995) con 250 días:

[7] propone un test de proporción de fallos (POF). Sea x el número de días en que las pérdidas superan el VaR al nivel $(1 - p)$ en $T = 250$ observaciones. Bajo $H_0 : \Pr(\text{excedencia}) = p$:

$$\text{LR}_{\text{POF}} = -2 \ln \left[\frac{(1-p)^{T-x} p^x}{\left(1 - \frac{x}{T}\right)^{T-x} \left(\frac{x}{T}\right)^x} \right] \sim \chi^2(1)$$

Para VaR al 99% ($p = 0.01$), se espera $T \times p = 2.5$ excedencias. Valores típicamente aceptables: $x \in \{0, 1, 2, 3, 4, 5\}$ (zona de no rechazo al 95%).

Aplicación: si se observan $x = 8$ excedencias en 250 días: $\hat{p} = 8/250 = 0.032$.
 $\text{LR} = -2 \ln[(0.99^{242} \times 0.01^8)/(0.968^{242} \times 0.032^8)]$

Si $\text{LR} > \chi_{0.05}^2(1) = 3.84$, se rechaza el modelo (subvalora el riesgo).

Ejercicio 9 — SARIMAX multivariable para precio de materias primas

Precio mensual WTI (log) con SARIMAX(0, 1, 1)(1, 1, 0)₁₂; exógenas: REER (x_{1t}) y PMI global (x_{2t}).

Parám.	Est.	e.e.	p-val
$\hat{\theta}$	-0.634	0.0821	0.0000
$\hat{\Phi}$	-0.291	0.0654	0.0000
$\hat{\beta}_1$	-0.412	0.1340	0.0022
$\hat{\beta}_2$	+0.587	0.2100	0.0053

Solución**a) Interpretación de $\hat{\beta}_1 = -0.412$ y $\hat{\beta}_2 = +0.587$:**

$\hat{\beta}_1 = -0.412$ (REER): Un incremento de 1 unidad en el índice de tipo de cambio real efectivo (apreciación de la moneda del país importador de petróleo) reduce log(WTI) en 0.412 puntos. **Es coherente con la teoría:** cuando el dólar se aprecia (REER sube), el petróleo denominado en dólares se encarece para compradores extranjeros, reduciendo la demanda global y el precio.

$\hat{\beta}_2 = +0.587$ (PMI global): Un incremento de 1 punto en el PMI manufacturero global incrementa log(WTI) en 0.587 puntos. **Es coherente:** un PMI alto refleja mayor actividad industrial y demanda de energía, presionando al alza los precios del petróleo.

b) Pronóstico puntual a 3 meses:

Con $\Delta x_{1,t+k} = 0$ y $\Delta x_{2,t+k} = +1.5$ para $k = 1, 2, 3$, y supuesto de rezagos AR y MA nulos al horizonte 3:

La ecuación de pronóstico en forma diferenciada para $k = 1, 2, 3$:

$$\Delta \widehat{\log P_{t+k}} = \hat{\beta}_1 \Delta x_{1,t+k} + \hat{\beta}_2 \Delta x_{2,t+k} = (-0.412)(0) + (0.587)(+1.5) = 0.881$$

Por tanto, la contribución acumulada del PMI a lo largo de 3 meses:

$$\widehat{\log P_{t+3}} - \widehat{\log P_t} \approx 3 \times 0.881 = 2.642$$

(acumulando los tres choques mensuales del PMI, sin efecto REER). En niveles: $\hat{P}_{t+3} \approx P_t \times e^{2.642} \approx P_t \times 14.04$.

Nota: este resultado parece grande porque $\Delta x_2 = +1.5$ unidades mensuales durante 3 meses es un incremento notable del PMI. En la práctica, los choques de PMI son pequeños ($\pm 1-2$ puntos).

Para cada horizonte $k=1,2,3$, la contribución exógena esperada es: $12\log P_{t+k} = 0.587(1.5)=0.8805$

Si se acumulan los tres impactos mensuales, el efecto acumulado sería: $3(0.8805)=2.6415$

c) Endogeneidad del PMI y consistencia de $\hat{\beta}_2$:

Si el precio del WTI retroalimenta al PMI (petróleo caro reduce la producción industrial), entonces $\text{Cov}(\text{PMI}_t, \varepsilon_t) \neq 0$, violando la exogeneidad estricta. Esto provoca **sesgo de simultaneidad**: $\hat{\beta}_2$ OLS o QML sobreestimaría (en valor absoluto) el efecto causal del PMI.

Método de corrección: Variables Instrumentales (IV) o Mínimos Cuadrados en Dos Etapas (2SLS). Se busca un instrumento w_t tal que: (i) $\text{Cov}(w_t, \text{PMI}_t) \neq 0$ (relevancia) y (ii) $\text{Cov}(w_t, \varepsilon_t) = 0$ (exogeneidad). Por ejemplo, el PMI de EE.UU. rezagado dos trimestres o un índice de comercio global exógeno.

d) Residuales del SARIMAX como regresores en GARCH:

No viola supuestos en una estimación de **dos etapas**: primero se estima el SARIMAX para obtener $\hat{\varepsilon}_t$, luego se ajusta GARCH sobre $\hat{\varepsilon}_t$.

Sin embargo, hay consideraciones: (i) la incertidumbre de la primera etapa no se propaga a la segunda (errores estándar subestimados en GARCH); (ii) si los residuales SARIMAX contienen estructura ARCH significativa, el GARCH la captura correctamente; (iii) idealmente se estimaría el SARIMAX-GARCH en forma conjunta por MV, pero la estimación en dos etapas es consistente aunque no eficiente.

Ejercicio 10 — Selección de modelo y pronóstico de volatilidad

Modelo	AIC	BIC	Params	LB($\hat{z}^2$) p
GARCH(1, 1) Normal	3 241.80	3 258.40	4	0.431
GARCH(1, 1) t	3 228.50	3 249.60	5	0.512
EGARCH(1, 1) t	3 226.10	3 251.60	6	0.498
GJR-GARCH(1, 1, 1) t	3 224.30	3 253.30	7	0.487
GARCH(2, 2) Normal	3 239.60	3 278.50	6	0.391

Solución**a) Selección por AIC vs BIC:**

Por **AIC**: GJR-GARCH(1, 1, 1)- t con AIC = 3 224.30 (el más bajo).

Por **BIC**: GARCH(1, 1)-Normal con BIC = 3 258.40 (el más bajo).

Por qué divergen: el BIC penaliza más fuertemente los parámetros adicionales [$\text{BIC} = -2\ell + k \ln n$ vs $\text{AIC} = -2\ell + 2k$]. Con n grande (datos diarios, probablemente $n > 500$), $\ln n > 2$, por lo que BIC penaliza más la complejidad y prefiere modelos más parsimoniosos. AIC favorece el ajuste; BIC favorece la parsimonia.

b) GARCH(2, 2) con AIC mayor al GARCH(1, 1) Normal con más parámetros:

Implica que los rezagos adicionales (α_2, β_2) en GARCH(2, 2) no mejoran el ajuste (log-verosimilitud) lo suficiente para compensar la penalización por dos parámetros extra. Los rezagos adicionales no son útiles: toda la información relevante de la estructura ARCH/GARCH está contenida en el orden (1, 1). Esto es coherente con la literatura: GARCH(1, 1) es usualmente suficiente para datos financieros.

c) $\text{LB}(\hat{z}^2)$ $p > 0.05$ en todos los modelos:

La familia GARCH es adecuada para estos datos: todos los modelos capturan la heterocedasticidad condicional de los residuales. La elección entre ellos debe basarse en criterios de información (AIC/BIC), distribución de innovaciones, y posible asimetría, no en diferencias de ajuste a la estructura ARCH/GARCH.

d) Pronóstico $\hat{\sigma}_{t+k}^2$ a 5 días para GARCH(1, 1)- t :

Con $\hat{\sigma}_{t+1}^2 = 0.0025$, $\bar{\sigma}^2 = 0.0018$ y $\hat{\alpha} + \hat{\beta} = 0.963$:

$$\mathbb{E}_t[\sigma_{t+k}^2] = \bar{\sigma}^2 + (0.963)^{k-1}(\sigma_{t+1}^2 - \bar{\sigma}^2) = 0.0018 + (0.963)^{k-1}(0.0025 - 0.0018)$$

$$= 0.0018 + (0.963)^{k-1} \times 0.0007$$

k	$(0.963)^{k-1}$	$\mathbb{E}[\sigma_{t+k}^2]$	$\hat{\sigma}_{t+k}$ (%)
1	1.000	0.0025000	5.000
2	0.963	0.0024741	4.974
3	0.927	0.0024489	4.949
4	0.893	0.0024251	4.925
5	0.860	0.0024020	4.902

La volatilidad converge lentamente hacia $\bar{\sigma} = \sqrt{0.0018} \approx 4.24\%$.

e) Recomendación para VaR al 99% a 10 días bajo Basilea III:

Se recomienda **GJR-GARCH(1, 1, 1)- t** por las siguientes razones: (i) tiene el mejor AIC, capturando la dinámica de volatilidad con mayor fidelidad; (ii) la distribución t -Student genera cuantiles de cola más conservadores, apropiados para VaR al 99%; (iii) el término asimétrico λ captura el mayor impacto de caídas del mercado sobre la volatilidad futura, crucial para capital regulatorio en renta fija con bonos de emisores que pueden ser afectados negativamente por eventos de crédito. El BIC bajo GARCH Normal sería adecuado solo si la parsimonia fuera el objetivo primario; en regulación prudencial, se prioriza la precisión en cola.

Parte B — Preguntas estilo CFA (opción múltiple)

Instrucciones

Formato CFA Level III — Gestión de Portafolios y Riesgo Cuantitativo. La respuesta correcta aparece en **negritas**. Se incluye justificación de todas las opciones.

Pregunta CFA 11

Un analista observa que los log-rendimientos de un portafolio presentan ACF no significativa en todos los rezagos, pero ACF significativa y positiva en r_t^2 a los rezagos 1, 5 y 10. ¿Cuál es la inferencia más apropiada?

- A. Los rendimientos son i.i.d.
- B. Los rendimientos exhiben heterocedasticidad condicional (efecto ARCH): un modelo GARCH es apropiado para la varianza condicional.**
- C. Los rendimientos tienen autocorrelación en la media que requiere un modelo ARMA.
- D. Los rendimientos siguen una caminata aleatoria con tendencia determinista.

Solución

B es correcta. La firma característica del efecto ARCH es exactamente la observada: r_t sin autocorrelación (la media condicional es constante, no requiere ARMA) pero r_t^2 con autocorrelación significativa (la varianza condicional depende del pasado).

Pregunta CFA 12

El GARCH(1, 1) para EUR/USD produce $\hat{\alpha} = 0.08$ y $\hat{\beta} = 0.91$. Un gestor afirma que la volatilidad revertirá rápidamente a su media tras un choque. ¿Es correcta esta afirmación?

- A. Sí, porque $\hat{\alpha} < 0.10$ indica baja sensibilidad a nuevos choques.
- B. No; la persistencia $\hat{\alpha} + \hat{\beta} = 0.99$ implica reversión muy lenta: los choques tardan muchos periodos en disiparse.**
- C. Sí, porque $\hat{\beta} > 0.90$ garantiza estacionariedad estricta.
- D. No; para reversión rápida se necesita $\hat{\alpha} + \hat{\beta} > 1$.

Solución

B es correcta. La tasa de reversión a la media de σ_t^2 está gobernada por $(1 - \alpha - \beta) = 1 - 0.99 = 0.01$ por periodo. Después de 10 días persiste el $(0.99)^{10} = 90.4\%$ del desvío; después de 100 días, el 36.6%. La reversión es extremadamente lenta.

Pregunta CFA 13

Al comparar EGARCH(1, 1) con GARCH(1, 1), ¿cuál afirmación es más precisa?

- A. El EGARCH requiere $\omega > 0$, $\alpha \geq 0$ y $\beta \geq 0$ igual que el GARCH.
- B. **El EGARCH modela $\log \sigma_t^2$ sin restricciones de signo y captura asimetría en el impacto de innovaciones positivas y negativas.**
- C. El EGARCH siempre tiene AIC menor al GARCH por su mayor flexibilidad.
- D. EGARCH y GARCH producen pronósticos de volatilidad idénticos en muestras grandes.

Solución

B es correcta. El EGARCH especifica $\log \sigma_t^2$, que es positivo para cualquier valor de los parámetros (sin restricciones de signo). Además, el término γz_{t-1} captura asimetría.

Pregunta CFA 14

Un fondo estima VaR diario al 99% con GARCH(1,1)- t ($\nu = 5$): VaR = \$2.1M. Con varianza histórica constante (250 días): VaR = \$1.6M. ¿Por qué el VaR-GARCH es mayor?

- A. Porque el GARCH siempre produce estimaciones conservadoras del VaR.
- B. **Porque la volatilidad condicional actual supera la volatilidad histórica promedio: sucede en periodos de alta tensión de mercado.**
- C. Porque la distribución t -Student tiene colas más delgadas que la normal.
- D. Porque el VaR histórico no considera correlación serial.

Solución

B es correcta. El VaR-GARCH usa $\hat{\sigma}_t$ (volatilidad de hoy), que en periodos de crisis supera $\bar{\sigma}$ (volatilidad histórica promedio). El VaR histórico usa $\bar{\sigma}$, subestimando el riesgo cuando los mercados están agitados.

Pregunta CFA 15

Un analista incluye el VIX como variable exógena x_t en un SARIMAX para rendimientos de un portafolio de opciones. ¿Cuál supuesto es el más crítico para la validez?

- A. El VIX debe seguir una distribución normal.
- B. **El VIX debe ser estrictamente exógeno: $\text{Cov}(x_t, \varepsilon_s) = 0$ para todo t, s , sin retroalimentación del portafolio hacia el VIX.**
- C. El VIX debe ser estacionario en niveles para incluirse directamente.
- D. El VIX debe tener el mismo orden de integración que la variable dependiente.

Solución

B es correcta. La exogeneidad estricta es el supuesto más crítico: si el portafolio de opciones mueve el VIX (lo cual es posible si el portafolio es grande), $\hat{\beta}$ sería

inconsistente por endogeneidad.

Pregunta CFA 16

La prueba de Ljung-Box sobre $\hat{z}_t^2$ de un GARCH arroja p-valor = 0.002. ¿Cuál es la conclusión correcta?

- A. El GARCH capturó adecuadamente la heterocedasticidad; los residuales son ruido blanco.
- B. **El GARCH no capturó toda la estructura de la varianza: persiste autocorrelación en $\hat{z}_t^2$; conviene incrementar los órdenes o cambiar la especificación.**
- C. La distribución de innovaciones es incorrecta y debe cambiarse por t -Student.
- D. Los rendimientos no son estacionarios y se requiere diferenciación adicional.

Solución

B es correcta. El diagnóstico GARCH central es que $\hat{z}_t^2 = (\hat{\varepsilon}_t/\hat{\sigma}_t)^2$ no debe tener autocorrelación. Un p-valor = 0.002 < 0.05 rechaza H_0 : el modelo GARCH actual no capturó toda la heterocedasticidad condicional. Se debe incrementar los órdenes (p, q) o explorar EGARCH/GJR-GARCH.

Pregunta CFA 17

El GARCH-M especifica $r_t = \mu + \delta\sigma_t + \varepsilon_t$. ¿Cuál es la interpretación financiera de $\hat{\delta} > 0$ significativo?

- A. **Existe una prima de riesgo positiva: los inversionistas exigen mayor retorno cuando la volatilidad condicional es mayor, consistente con la teoría de portafolios.**
- B. La volatilidad tiene efecto negativo sobre rendimientos futuros (reversión a la media).
- C. El modelo está mal especificado porque σ_t no puede entrar en la ecuación de la media.
- D. Los rendimientos son predecibles, contradiciendo la hipótesis de mercados eficientes.

Solución

A es correcta. $\hat{\delta} > 0$ implica $\partial \mathbb{E}_t[r_{t+1}]/\partial \sigma_{t+1} > 0$: el rendimiento esperado aumenta con la volatilidad esperada, capturando la compensación por riesgo. Esto es la relación positiva riesgo-retorno de la teoría moderna de portafolios.

Pregunta CFA 18

Al elegir entre GARCH(1, 1) Normal (AIC = 3241.8) y GARCH(1, 1)- t (AIC = 3228.5), ¿cuál afirmación es correcta?

- A. Se prefiere el Normal por ser más parsimonioso.
- B. **Se prefiere el modelo t : AIC menor indica que la mejora en ajuste por colas pesadas compensa el parámetro adicional ν .**
- C. No se pueden comparar AIC entre modelos con diferente distribución de innovaciones.
- D. La elección debe basarse solo en BIC para muestras mayores a 500 observaciones.

Solución

B es correcta. El AIC del modelo t (3228.5) es 13.3 puntos menor que el Normal (3241.8). La diferencia $\Delta\text{AIC} = 13.3$ es sustancial (umbral común: $\Delta\text{AIC} > 2$ es evidencia significativa a favor del mejor modelo). El parámetro adicional ν (grados de libertad) captura las colas pesadas y su penalización AIC (+2) es ampliamente compensada por la mejora en log-verosimilitud.

Pregunta CFA 19

Bajo **Basilea III**, un analista propone $\text{VaR}_{10} = \text{VaR}_1 \times \sqrt{10}$ con un modelo GARCH. ¿Cuál es la limitación principal?

- A. **La regla es exacta solo para rendimientos i.i.d. normales. Con *clustering* GARCH, la volatilidad no es constante: los pronósticos multi-periodo deben iterarse con la ecuación de varianza GARCH, no escalarse con $\sqrt{h}$.**
- B. La regla subestima el VaR porque no considera la distribución t -Student.
- C. El VaR no es sub-aditivo y no puede escalarse con el tiempo.
- D. Los modelos GARCH requieren ventanas de exactamente 250 días bajo Basilea III.

Solución

A es correcta. La regla $\sqrt{h}$ asume varianza constante e independencia temporal. Con GARCH, σ_t^2 es autocorrelacionada: tras un choque, la varianza permanece elevada durante múltiples periodos. Si $\hat{\sigma}_t > \bar{\sigma}$ (periodo de crisis), el VaR a 10 días verdadero $> \text{VaR}_1 \sqrt{10}$: la regla subestima el riesgo. La forma correcta es:

$$\text{Var}_t \left(\sum_{k=1}^{10} r_{t+k} \right) = \sum_{k=1}^{10} \mathbb{E}_t[\sigma_{t+k}^2]$$

Pregunta CFA 20

Un portafolio de bonos soberanos con SARIMAX(0, 1, 1)(1, 1, 0)₁₂ produce residuales con Jarque-Bera significativo (curtosis = 6.8) y Ljung-Box no significativo. ¿Cuál es el siguiente paso más adecuado?

- A. Aumentar los órdenes p y q del SARIMAX.

- B. El modelo es adecuado; el JB no afecta la consistencia de los estimadores MV.
- C. **Mantener el SARIMAX para la media y reestimar con quasi-MV (QML) o distribución t -Student para obtener inferencia válida bajo colas pesadas.**
- D. Agregar diferencia estacional adicional $D = 2$ para eliminar la curtosis.

Solución

C es correcta. El Ljung-Box no significativo confirma que la estructura de la media condicional (SARIMA) es adecuada: no se necesita aumentar p o q . Sin embargo, curtosis = $6.8 \gg 3$ indica colas pesadas, lo que invalida la inferencia basada en MV gaussiano (errores estándar y tests t serían incorrectos). La solución es: (i) QML: mantener el modelo pero usar errores estándar robustos (Bollerslev-Wooldridge); o (ii) reestimar con distribución t -Student para ε_t .

B es parcialmente correcta (QML es consistente bajo no-normalidad) pero incompleta: la inferencia (tests, IC) requiere corrección.

References

- [1] Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- [2] Box, G. E. P., & Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day. doi:10.1002/9781118619193
- [3] Christie, A. A. (1982). The stochastic behavior of common stock variances. *Journal of Financial Economics*, 10(4), 407–432. doi:10.1016/0304-405X(82)90018-6
- [4] Engle, R. F., & Ng, V. K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778. doi:10.1111/j.1540-6261.1993.tb05127.x
- [5] Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801. doi:10.1111/j.1540-6261.1993.tb05128.x
- [6] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts. <https://otexts.com/fpp2/>
- [7] Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- [8] Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2), 347–370. doi:10.2307/2938260