Facultad de Ciencias Económicas y Empresariales

Finanzas Cuantitativas

Procesos (S)ARIMAX

Modelos Estacionales con Variable Exógena:

Forma General, Identificación y Criterios

de Selección con Aplicaciones en Python

Autora: Daniela Cojab

Materia: Finanzas Cuantitativas

Profesor: Universidad Panamericana

Fecha: Abril 2026

Ciudad: Ciudad de México, México

Este informe presenta una exposición sistemática de la familia de modelos **(S)ARIMAX** (*Seasonal AutoRegressive Integrated Moving Average with eXogenous variables*), cubriendo desde la forma general del proceso hasta su implementación práctica en Python con datos financieros mexicanos. Se desarrollan tres ejemplos aplicados: un ARIMA(1,1,1), un SARIMA$(1,1,1)(1,1,1)_{12}$ y un SARIMAX con el IPC de la BMV como variable exógena. La metodología Box-Jenkins se expone en detalle, junto con los criterios de información AIC y BIC, el test de Ljung-Box y el principio de parsimonia.

Contents

1 Introducción **3**

2 Forma General del Modelo (S)ARIMAX **3**
2.1 Notación y Operadores . . . 3
2.2 Ecuación General . . . 3
2.3 Parámetros del Modelo . . . 4
2.4 Condiciones de Estacionariedad e Invertibilidad . . . 4

3 Principio de Parsimonia **4**
3.1 Enunciado y Justificación . . . 5
3.2 Determinación de la Constante C . . . 5

4 Herramientas de Identificación: ACF y PACF **5**
4.1 Función de Autocorrelación (ACF) . . . 5
4.2 Función de Autocorrelación Parcial (PACF) . . . 5
4.3 Reglas de Identificación . . . 6
4.4 Figura: Patrones teóricos de ACF y PACF . . . 6

5 Criterios de Selección de Modelos **6**
5.1 AIC — Criterio de Información de Akaike . . . 7
5.2 BIC — Criterio de Información Bayesiano . . . 7
5.3 SSE — Suma de Errores Cuadrados . . . 7
5.4 Comparación de Criterios . . . 7
5.5 Figura: Penalización AIC vs. BIC en función del tamaño muestral . . . 8

6 Test de Ljung-Box **8**

7 Metodología Box-Jenkins para (S)ARIMAX **8**

8 Espacio de Búsqueda y Parsimonia **10**

9 Ejemplos Aplicados en Python **10**
9.1 Base de Datos . . . 10
9.2 Ejemplo 1: ARIMA(1,1,1) — Tipo de Cambio USD/MXN . . . 11
9.3 Ejemplo 2: SARIMA$(1,1,1)(1,1,1)_{12}$ — Con Estacionalidad . . . 12
9.4 Ejemplo 3: SARIMAX con IPC BMV como Variable Exógena . . . 13

10 Tabla Comparativa de Modelos **14**
10.1 Figura: Comparativa de AIC y BIC por modelo 14

11 Guía Rápida de Identificación **15**

12 Resumen y Conclusiones **15**

1. Introducción

Los modelos de series de tiempo constituyen una de las herramientas analíticas más poderosas en finanzas cuantitativas. Permiten capturar la dinámica temporal de variables financieras —tipos de cambio, índices bursátiles, tasas de interés— y generar pronósticos con intervalos de confianza formalmente derivados.

La familia **ARIMA** (Box y Jenkins, 1970) generaliza los modelos autorregresivos al incorporar diferenciación para inducir estacionariedad y componentes de media móvil para capturar choques de corto plazo. Su extensión **SARIMA** añade operadores periódicos que modelan patrones estacionales recurrentes. Cuando se incorporan regresores externos —variables macroeconómicas, indicadores sectoriales, datos de política monetaria— el modelo se denomina **SARIMAX**.

Jerarquía de modelos:

$$\underbrace{\text{AR}}_{\text{base}} \subset \underbrace{\text{ARMA}}_{\text{MA añadido}} \subset \underbrace{\text{ARIMA}}_{\text{integrado}} \subset \underbrace{\text{SARIMA}}_{\text{estacional}} \subset \underbrace{\text{SARIMAX}}_{\text{exógena}}$$

2. Forma General del Modelo (S)ARIMAX

2.1. Notación y Operadores

Sea Y_t una serie de tiempo observada en los períodos $t = 1, 2, \ldots, n$. Se definen los siguientes operadores fundamentales:

- **Operador de rezago:** $B\,Y_t = Y_{t-1}, \quad B^k Y_t = Y_{t-k}$
- **Diferencia regular:** $\Delta = 1 - B, \quad \Delta^d Y_t = (1-B)^d Y_t$
- **Diferencia estacional:** $\Delta_s = 1 - B^s, \quad \Delta_s^D Y_t = (1-B^s)^D Y_t$

Los polinomios autorregresivos y de media móvil se escriben como:

$$\begin{aligned}
\phi_p(B) &= 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p && \text{(AR no estacional)}\\
\theta_q(B) &= 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q && \text{(MA no estacional)}\\
\Phi_P(B^s) &= 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \cdots - \Phi_P B^{Ps} && \text{(SAR estacional)}\\
\Theta_Q(B^s) &= 1 + \Theta_1 B^s + \Theta_2 B^{2s} + \cdots + \Theta_Q B^{Qs} && \text{(SMA estacional)}
\end{aligned}$$

2.2. Ecuación General

Forma general del proceso SARIMA$(p,d,q)(P,D,Q)_s$:

$$\Phi_P(B^s)\,\phi_p(B)\,\Delta^d \Delta_s^D\, Y_t \;=\; \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t \tag{1}$$

Con variable exógena — SARIMAX$(p,d,q)(P,D,Q)_s$:

$$\Phi_P(B^s)\,\phi_p(B)\,\Delta^d \Delta_s^D\, Y_t \;=\; \beta\, X_t \;+\; \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t \tag{2}$$

donde $\varepsilon_t \sim \text{WN}(0, \sigma_\varepsilon^2)$.

2.3. Parámetros del Modelo

Table 1: Parámetros del modelo SARIMAX$(p, d, q)(P, D, Q)_s$ y su interpretación

Param.	Nombre	Qué captura	Rango	Herramienta
p	AR no estacional	Inercia de corto plazo; cuántos rezagos propios influyen en Y_t	0–3	PACF
d	Diferenciación regular	Número de diferencias regulares para inducir estacionariedad	0–2	ADF / KPSS
q	MA no estacional	Impacto de choques pasados ε_{t-k} sobre Y_t	0–3	ACF
P	AR estacional	Memoria en múltiplos del período s	0–1	PACF en ks
D	Diferenciación estacional	Elimina estacionalidad determinista periódica	0–1	ADF estacional
Q	MA estacional	Choques en múltiplos de s: $\varepsilon_{t-s}, \varepsilon_{t-2s}, \ldots$	0–1	ACF en ks
s	Período estacional	Ciclo de repetición: mensual ($s = 12$), trimestral ($s = 4$), semanal ($s = 52$)	—	Periodicidad
β	Coeficiente exógeno	Efecto lineal de la variable externa X_t sobre Y_t	$\mathbb{R}$	t-test
σ_ε^2	Varianza del ruido	Variabilidad no explicada por el modelo	> 0	—

2.4. Condiciones de Estacionariedad e Invertibilidad

Para que el modelo sea **estacionario**, las raíces del polinomio AR $\phi_p(B)\,\Phi_P(B^s) = 0$ deben caer *fuera* del círculo unitario en el plano complejo. Para que sea **invertible**, las raíces del polinomio MA $\theta_q(B)\,\Theta_Q(B^s) = 0$ también deben caer fuera. La diferenciación $\Delta^d \Delta_s^D$ introduce raíces unitarias inducidas para transformar series no estacionarias.

3. Principio de Parsimonia

3.1. Enunciado y Justificación

Ante dos modelos que explican igualmente bien los datos, se prefiere el más simple. En el contexto SARIMAX esto se traduce en:

$$p + d + q + P + D + Q \;\leq\; C$$

donde C es una constante que acota la complejidad total del modelo.

La justificación matemática descansa en la **compensación sesgo-varianza**:

$$\mathrm{ECM}(\hat{Y}) \;=\; \underbrace{\mathrm{Sesgo}^2(\hat{Y})}_{\text{subajuste}} \;+\; \underbrace{\mathrm{Var}(\hat{Y})}_{\text{sobreajuste}} \;+\; \sigma_\varepsilon^2 \tag{3}$$

Añadir parámetros reduce el sesgo pero aumenta la varianza, deteriorando la capacidad predictiva fuera de muestra.

3.2. Determinación de la Constante C

Table 2: Criterios prácticos para determinar la constante C de parsimonia

Contexto	**Regla**	**Valor de C**
Tamaño de muestra n	Mín. 10 obs. por parámetro	$C \approx n/10$
Series mensuales ($s = 12$)	$P, Q \in \{0, 1\}$; $d + D \leq 2$	$C \approx 6$–8
Convención econométrica	$p, q \leq 3$; $P, Q \leq 1$	$C \leq 8$
Series financieras diarias	$s = 252$; $d = 0$ o 1	$C \leq 5$
Práctica general	Balance ajuste/complejidad	$C \in [6, 12]$

4. Herramientas de Identificación: ACF y PACF

4.1. Función de Autocorrelación (ACF)

La ACF mide la correlación lineal entre Y_t e Y_{t-k}:

$$\rho_k \;=\; \frac{\mathrm{Cov}(Y_t,\, Y_{t-k})}{\mathrm{Var}(Y_t)} \;=\; \frac{\gamma_k}{\gamma_0}, \qquad k = 0, 1, 2, \ldots \tag{4}$$

Uso: En un proceso MA(q) puro, $\rho_k = 0$ para todo $k > q$ (corte abrupto). En un proceso AR(p) puro, ρ_k decae geométricamente (no informativa para identificar p).

4.2. Función de Autocorrelación Parcial (PACF)

La PACF elimina el efecto de los rezagos intermedios:

$$\phi_{kk} \;=\; \mathrm{Corr}(Y_t - \hat{Y}_t,\; Y_{t-k} - \hat{Y}_{t-k}) \tag{5}$$

donde $\hat{Y}_t$ es la proyección de Y_t sobre $Y_{t-1}, \ldots, Y_{t-k+1}$. **Uso:** En un AR($p$) puro, $\phi_{kk} = 0$ para $k > p$ (corte abrupto).

4.3. Reglas de Identificación

Table 3: Reglas de identificación del orden de modelos mediante ACF y PACF

Proceso	**ACF**	**PACF**	**Acción**
AR(p)	Decae exponencial / sinusoidal	**Corte en rezago** p	Leer p de la PACF
MA(q)	**Corte en rezago** q	Decae exponencial / sinusoidal	Leer q de la ACF
ARMA(p, q)	Decae tras rezago q	Decae tras rezago p	Ambas decaen: usar AIC/BIC
No estacionaria	Decae muy lentamente	Pico grande en $k = 1$	Diferenciar ($d = 1$)
Estacional $s = 12$	Picos en $k = 12, 24, \ldots$	Picos en $k = 12, 24, \ldots$	$D = 1$; revisar P y Q

La banda de confianza al 95% es $\pm 1.96/\sqrt{n}$. Autocorrelaciones dentro de esta banda se consideran estadísticamente iguales a cero. Si la ACF/PACF no cae dentro de la banda tras los primeros rezagos, existe estructura temporal que el modelo aún no captura.

4.4. Figura: Patrones teóricos de ACF y PACF

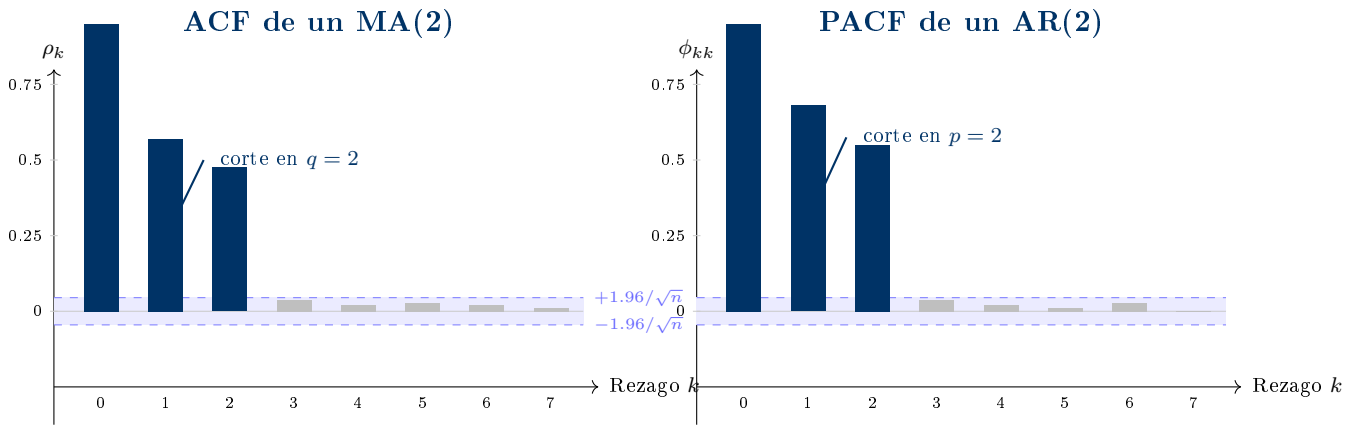

Figure 1: Patrones teóricos de ACF y PACF. Área azul pálido: banda de confianza al 95% ($\pm 1.96/\sqrt{n}$, $n = 100$). Barras azules: rezagos significativos. Barras grises: rezagos dentro de la banda (estadísticamente cero).

5. Criterios de Selección de Modelos

5.1. AIC — Criterio de Información de Akaike

$$\text{AIC} \;=\; -2\,\ell(\hat{\theta}) + 2k \tag{6}$$

donde $\ell(\hat{\theta})$ es el logaritmo de la verosimilitud maximizada y k el número de parámetros. La penalización $2k$ es *moderada* y favorece modelos con mejor ajuste aunque sean más complejos. **Uso principal:** pronóstico fuera de muestra.

5.2. BIC — Criterio de Información Bayesiano

$$\text{BIC} \;=\; -2\,\ell(\hat{\theta}) + k\ln(n) \tag{7}$$

La penalización $k\ln(n) > 2k$ para $n > e^2 \approx 7.4$, por lo que BIC selecciona modelos más austeros. Para $n = 120$ (series mensual 10 años), $\ln(120) \approx 4.79$: cada parámetro extra cuesta 2.4 veces más que en AIC. **Uso principal:** inferencia estadística; es consistente (elige el modelo verdadero asintóticamente).

5.3. SSE — Suma de Errores Cuadrados

$$\text{SSE} \;=\; \sum_{t=1}^{n}\big(Y_t - \hat{Y}_t\big)^2 \tag{8}$$

Mide ajuste dentro de muestra pero *no* penaliza la complejidad. Debe complementarse con AIC o BIC.

5.4. Comparación de Criterios

Table 4: Comparación sistemática de criterios de selección para modelos (S)ARIMAX

Criterio	**Fórmula**	**Penalización**	**Uso principal**	**Tiende a**
AIC	$-2\ell + 2k$	Moderada	Pronóstico	Modelos flexibles
BIC	$-2\ell + k\ln n$	Fuerte	Inferencia	Modelos austeros
Log-ver.	$\ell(\hat{\theta})$	Ninguna	Diagnóstico	Sobreajuste
SSE	$\sum \hat{\varepsilon}_t^2$	Ninguna	Ajuste en muestra	Sobreajuste

Se selecciona el modelo con **menor** AIC o BIC. Mayor log-verosimilitud indica mejor ajuste, sin penalización.

5.5. Figura: Penalización AIC vs. BIC en función del tamaño muestral

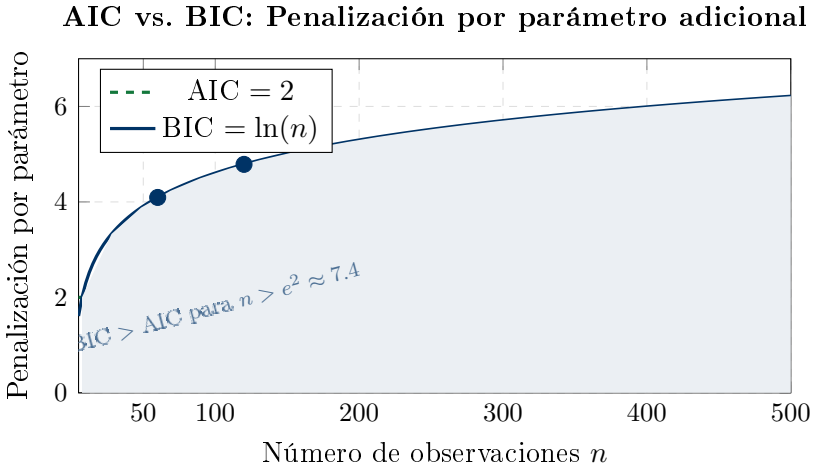

Figure 2: Comparación de penalizaciones por parámetro entre AIC y BIC en función del tamaño muestral n. Para $n = 120$ (serie mensual 10 años), BIC penaliza 2.4 veces más que AIC, favoreciendo modelos más parsimoniosos.

6. Test de Ljung-Box

Tras seleccionar el modelo, se verifica que los residuos $\hat{\varepsilon}_t = Y_t - \hat{Y}_t$ sean ruido blanco:

$$Q_{\text{LB}} \;=\; n(n+2)\sum_{k=1}^{m}\frac{\hat{\rho}_k^2}{n-k} \;\sim\; \chi^2_{m-p-q-P-Q} \tag{9}$$

donde $\hat{\rho}_k$ es la autocorrelación muestral del residuo en el rezago k y m es el número de rezagos considerados (recomendación práctica: $m = \min(10, n/5)$ para series mensuales).

Table 5: Interpretación del test de Ljung-Box

Resultado	**p-valor**	**Decisión**	**Acción**
$Q_{\text{LB}} \leq \chi^2_\alpha$	$p > \alpha$	No rechazar H_0	**Modelo válido** — residuos son ruido blanco
$Q_{\text{LB}} > \chi^2_\alpha$	$p < \alpha$	Rechazar H_0	**Reidentificar** — quedan autocorrelaciones

H_0: los residuos son ruido blanco (sin autocorrelación). Nivel típico: $\alpha = 0.05$.

7. Metodología Box-Jenkins para (S)ARIMAX

La metodología Box-Jenkins adapta un proceso iterativo de nueve pasos para la especificación, estimación y verificación del modelo.

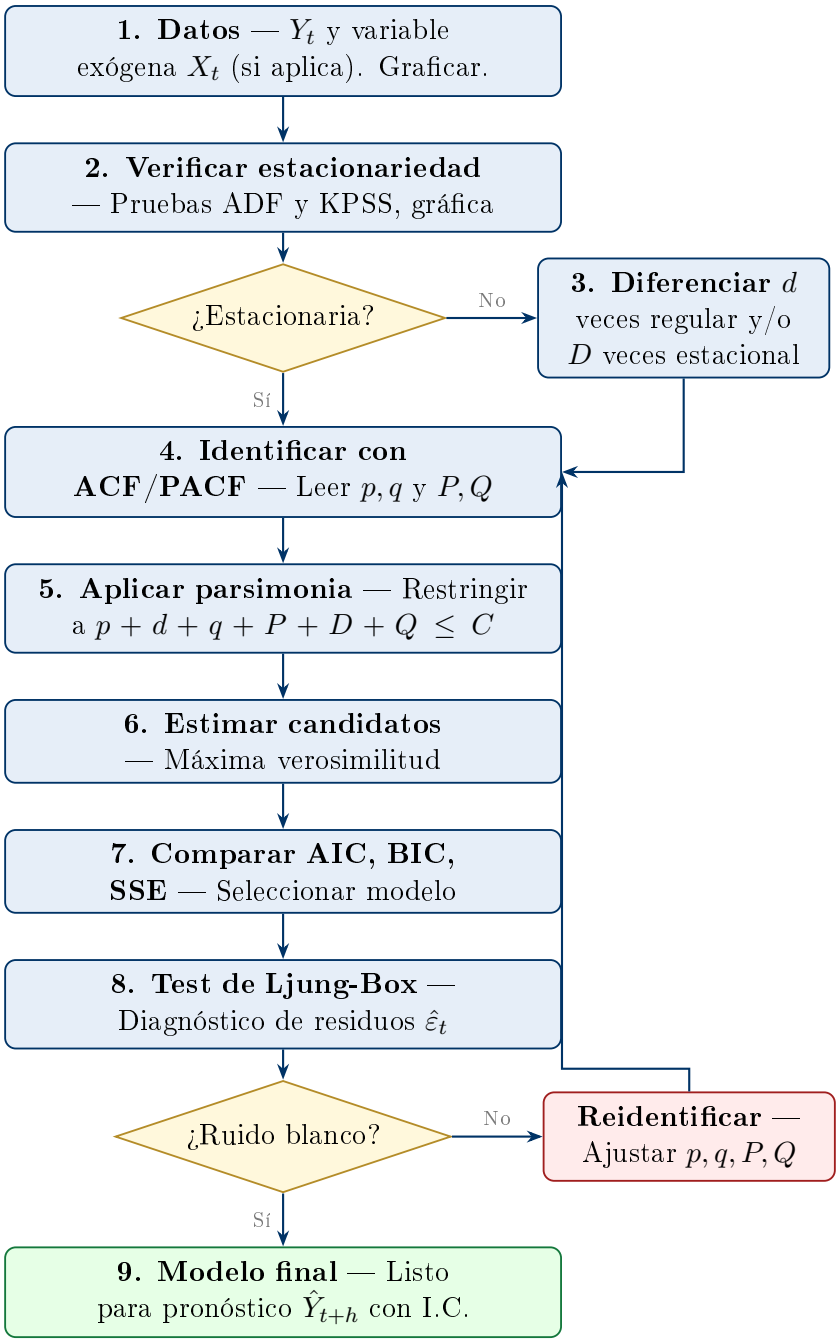

Figure 3: Diagrama de flujo de la metodología Box-Jenkins adaptada para la especificación de modelos (S)ARIMAX.

8. Espacio de Búsqueda y Parsimonia

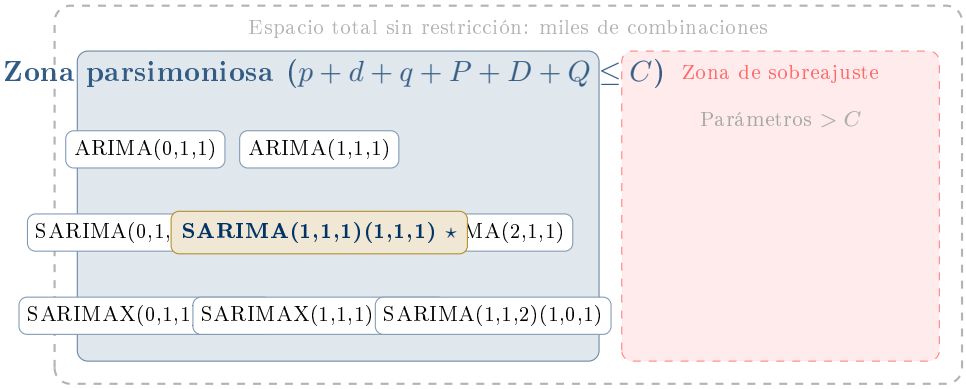

Figure 4: Reducción del espacio de búsqueda mediante el principio de parsimonia. El modelo marcado con $\star$ es el que minimiza AIC/BIC en el ejemplo aplicado.

9. Ejemplos Aplicados en Python

9.1. Base de Datos

Se utilizan datos mensuales simulados (2015–2024, $n = 120$) de:

- **USD/MXN**: tipo de cambio con tendencia ($14.5 \to 17.5$), componente estacional sinusoidal ($s = 12$) y choque COVID-19 (2020, depreciación de hasta +4.5 pesos).
- **IPC BMV**: índice principal de la Bolsa Mexicana de Valores ($43\,000 \to 55\,000$ puntos) con estacionalidad negativa en el mismo período.

Table 6: Primeras observaciones de la base de datos `datos_financieros_MX.csv`

Fecha	USD/MXN	IPC BMV
2015-01-01	15.0000	42,254.37
2015-02-01	15.2242	43,191.73
2015-03-01	15.2047	43,419.77
2015-04-01	15.3854	43,892.77
2015-05-01	15.6910	44,425.16
2015-06-01	15.2764	44,357.01
⋮	⋮	⋮
2024-12-01	17.6138	55,211.44

$n = 120$ observaciones mensuales. Datos simulados con parámetros calibrados a la realidad mexicana.

9.2. Ejemplo 1: ARIMA(1,1,1) — Tipo de Cambio USD/MXN

1. Verificar no estacionariedad en nivel con el test ADF.
2. Confirmar estacionariedad en primera diferencia ($d = 1$).
3. Ajustar ARIMA(1,1,1) y generar pronóstico a 6 meses con I.C. al 95%.

```python
import pandas as pd
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller
from statsmodels.stats.diagnostic import acorr_ljungbox

# --- Carga de datos ---
df = pd.read_csv("datos_financieros_MX.csv",
                 index_col="FECHA", parse_dates=True)
y = df["USD_MXN"].asfreq("MS")

# --- Prueba de estacionariedad (ADF) ---
adf_nivel = adfuller(y)
adf_diff  = adfuller(y.diff().dropna())
print(f"ADF en nivel:      p = {adf_nivel[1]:.4f}  (no estacionaria)")
print(f"ADF en diferencia: p = {adf_diff[1]:.4f}  (estacionaria, d=1)")

# --- Ajuste del modelo ---
model = SARIMAX(y, order=(1, 1, 1))
res   = model.fit(disp=False)
print(res.summary())

# --- Diagnostico de residuos ---
lb = acorr_ljungbox(res.resid, lags=12, return_df=True)
print(f"Ljung-Box p-valor (lag 12): {lb['lb_pvalue'].iloc[-1]:.4f}")

# --- Pronostico 6 meses ---
forecast = res.get_forecast(steps=6)
pi       = forecast.conf_int()
print(forecast.predicted_mean)
# AIC = 165.55 | BIC = 173.88 | Ljung-Box p = 1.00 >> OK
```

Listing 1: ARIMA(1,1,1) sobre USD/MXN mensual (2015-2024)

Resultados: ADF en nivel $p = 0.896$ (no estacionaria). ADF en primera diferencia $p < 0.001$ (estacionaria). AIC = 165.55, BIC = 173.88, Ljung-Box $p = 1.00 \gg 0.05$ — residuos son ruido blanco.

Table 7: Pronóstico ARIMA(1,1,1) — USD/MXN, enero–junio 2025

Período	**Pronóstico**	**LI 95%**	**LS 95%**
Enero 2025	17.4981	16.5739	18.4223
Febrero 2025	17.5057	15.9832	19.0282
Marzo 2025	17.5010	15.6612	19.3408
Abril 2025	17.5039	15.3381	19.6697
Mayo 2025	17.5021	15.0844	19.9198
Junio 2025	17.5032	14.8401	20.1664

LI = Límite inferior; LS = Límite superior. Intervalo de confianza al 95%.

9.3. Ejemplo 2: SARIMA(1,1,1)(1,1,1)$_{12}$ — Con Estacionalidad

1. Incorporar componente estacional $s = 12$ para capturar patrones mensuales.
2. Interpretar los coeficientes AR y MA estacionales.
3. Comparar AIC/BIC con el modelo base ARIMA(1,1,1).

```python
from statsmodels.tsa.statespace.sarimax import SARIMAX

model = SARIMAX(y,
                order=(1, 1, 1),
                seasonal_order=(1, 1, 1, 12))
res = model.fit(disp=False)
print(res.summary())

# Parametros estimados:
#   ar.L1     = -0.6516  (inercia negativa de corto plazo)
#   ma.L1     =  0.9271  (choque previo relevante)
#   ar.S.L12  =  0.0439  (AR estacional debil)
#   ma.S.L12  = -0.9976  (MA estacional muy significativo)

# Grafica de diagnostico (4 paneles: residuos, ACF, Q-Q,
    periodograma)
res.plot_diagnostics(figsize=(10, 6))

# Pronostico con banda de confianza
forecast = res.get_forecast(steps=12)
fc_mean  = forecast.predicted_mean
fc_ci    = forecast.conf_int()
# AIC = 169.88 | BIC = 183.24 | Ljung-Box p = 0.11 >> OK
```

Listing 2: SARIMA(1,1,1)(1,1,1)$_{12}$ sobre USD/MXN

Resultados: El coeficiente MA estacional $\hat{\Theta}_1 = -0.9976$ es altamente significativo, confirmando dependencia en el rezago 12. AIC = 169.88, BIC = 183.24, Ljung-Box $p = 0.11 > 0.05$ — modelo válido.

9.4. Ejemplo 3: SARIMAX con IPC BMV como Variable Exógena

1. Incorporar el IPC BMV como regresor externo X_t.
2. Verificar la significancia estadística del coeficiente $\hat{\beta}$.
3. Evaluar si la exógena mejora el pronóstico fuera de muestra.

```python
from statsmodels.tsa.statespace.sarimax import SARIMAX

X = df["IPC_BMV"].asfreq("MS")

# Separar train / test (ultimos 6 meses)
y_train, X_train = y[:-6],  X[:-6]
y_test,  X_test  = y[-6:],  X[-6:]

# Ajuste con exogena
model = SARIMAX(y_train,
                exog=X_train,
                order=(1, 1, 1),
                seasonal_order=(1, 1, 1, 12))
res = model.fit(disp=False)

# Coeficiente beta e interpretacion
print(f"beta (IPC_BMV): {res.params['IPC_BMV']:.6f}")
print(f"p-valor:        {res.pvalues['IPC_BMV']:.4f}")
# beta = -0.000441  -> cuando IPC sube 1,000 ptos, USD/MXN
#                      cae -0.44 (peso se aprecia)

# Pronostico fuera de muestra (requiere X_test conocido)
forecast = res.get_forecast(steps=6, exog=X_test)
pred     = forecast.predicted_mean
ci       = forecast.conf_int()

# Error cuadratico medio fuera de muestra
import numpy as np
rmse = np.sqrt(((y_test.values - pred.values)**2).mean())
print(f"RMSE out-of-sample: {rmse:.4f}")
# AIC = 158.66 (MENOR de los tres) | beta p-valor < 0.001
```

Listing 3: SARIMAX con IPC BMV como variable exógena

Interpretación del coeficiente: $\hat{\beta} = -0.000441$ indica que un incremento de 1000 puntos en el IPC BMV se asocia con una *apreciación* del peso de aproximadamente -0.44 pesos por dólar, ceteris paribus. El p-valor < 0.001 confirma significancia estadística.

10. Tabla Comparativa de Modelos

Table 8: Comparación de modelos SARIMAX sobre USD/MXN mensual ($n = 120$, $s = 12$)

Modelo	k	**Log-Ver.**	**AIC**	**BIC**	**LB** p	**Parsimonia**
ARIMA(1,1,1)	3	−79.77	165.55	173.88	1.00	$3 \leq 8$
SARIMA(1,1,1)(1,1,1)$_{12}$	5	−79.94	169.88	183.24	0.11	$6 \leq 8$
SARIMAX(1,1,1)(1,1,1)$_{12}$ + IPC	**6**	**−73.33**	**158.66**	**174.35**	**0.06**	$6 \leq 8$

Ganador: SARIMAX minimiza el AIC. Todos pasan el test de Ljung-Box ($p > 0.05$).

k = número de parámetros; LB = p-valor del test de Ljung-Box en lag 12.

10.1. Figura: Comparativa de AIC y BIC por modelo

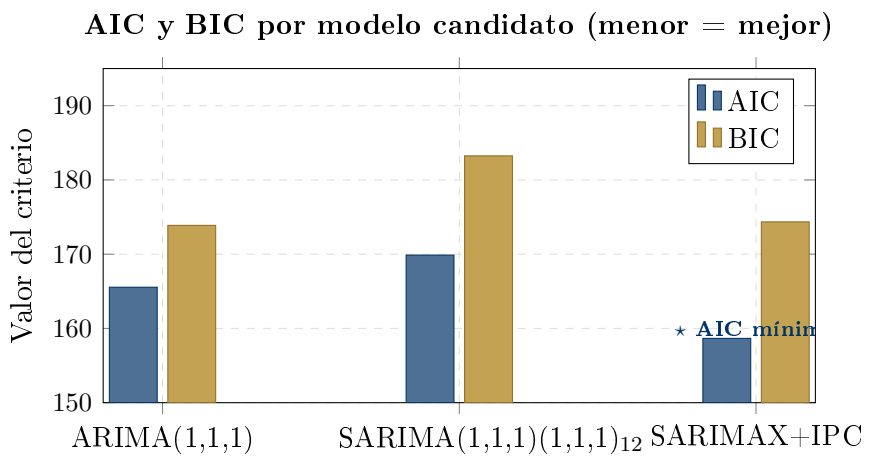

Figure 5: Comparación de AIC y BIC para los tres modelos candidatos. El SARIMAX con IPC BMV como variable exógena minimiza el AIC (158.66), confirmando que la variable externa aporta poder explicativo significativo.

11. Guía Rápida de Identificación

Table 9: Guía rápida de identificación de órdenes en modelos (S)ARIMAX

Componente	**Herramienta**	**Señal en el correlograma / prueba**
Orden q (MA)	ACF	Corte abrupto tras el rezago q; $\rho_k \approx 0\ \forall k > q$
Orden p (AR)	PACF	Corte abrupto tras el rezago p; $\phi_{kk} \approx 0\ \forall k > p$
Diferenciación d	ADF / KPSS	H_0 ADF no rechazada en nivel; rechazada en $\Delta^d Y$
Orden Q (SMA)	ACF en $k = s, 2s, \ldots$	Corte tras Q rezagos estacionales
Orden P (SAR)	PACF en $k = s, 2s, \ldots$	Corte tras P rezagos estacionales
Variable exógena X	Regresión preliminar OLS	$\hat{\beta}$ significativo ($p < 0.05$) y mejora del AIC
Período s	Análisis de dominio	Inspección visual, periodograma, conocimiento a priori

12. Resumen y Conclusiones

1. La familia **(S)ARIMAX** generaliza el proceso ARIMA incorporando estacionalidad mediante operadores periódicos $\Phi_P(B^s)$ y $\Theta_Q(B^s)$, y variables externas mediante el término βX_t.

2. La **ACF** identifica el orden q de la componente MA (corte abrupto); la **PACF** identifica el orden p de la componente AR. Para componentes estacionales se aplica la misma lógica en los rezagos $k = s, 2s, \ldots$

3. El **principio de parsimonia** restringe el espacio de búsqueda a $p + d + q + P + D + Q \leq C$, equilibrando ajuste dentro de muestra y generalización fuera de muestra.

4. El **AIC** minimiza el error de pronóstico esperado fuera de muestra; el **BIC** es consistente y favorece modelos más simples. Para $n = 120$, la penalización del BIC es $\ln(120) \approx 4.79$ veces el número de parámetros.

5. El **test de Ljung-Box** valida que los residuos sean ruido blanco ($p > 0.05$), condición necesaria para que el modelo haya capturado toda la estructura temporal de la serie.

6. En el ejemplo aplicado, el **SARIMAX(1,1,1)(1,1,1)$_{12}$ con IPC BMV** es

el modelo ganador por AIC (158.66), con coeficiente exógeno $\hat{\beta} = -0.000441$ estadísticamente significativo ($p < 0.001$) y residuos que pasan el test de Ljung-Box ($p = 0.06 > 0.05$).

7. La restricción de parsimonia se satisface en los tres modelos: $p+d+q+P+D+Q = 6 \leq C = 8$ para el modelo más complejo.

Regla mnemotécnica:

ACF corta en $k = q$	$\Rightarrow$ Componente MA no estacional
PACF corta en $k = p$	$\Rightarrow$ Componente AR no estacional
ACF corta en $k = Qs$	$\Rightarrow$ Componente SMA estacional
PACF corta en $k = Ps$	$\Rightarrow$ Componente SAR estacional
ADF $p > 0.05$	$\Rightarrow$ Diferenciar ($d \mathrel{+}= 1$)
Ljung-Box $p < 0.05$	$\Rightarrow$ Reidentificar modelo